

UNIVERSITATEA „SAPIENTIA” DIN
CLUJ-NĂPOCA
FACULTATEA DE ȘTIINȚE TEHNICE ȘI
UMANISTE,
TÂRGU MUREȘ
SPECIALIZAREA CALCULATOARE



UNIVERSITATEA
SAPIENTIA

Facultatea de Științe Tehnice și
Umaniste din Târgu-Mureș

Clasificarea imaginilor Roentgen de
plămâni cu ajutorul rețelelor
neuronale cu învățare profundă

PROIECT DE DIPLOMĂ

Coordonator științific:

Dr. habil. Szilágyi László

Absolvent:

Balázs Ákos

UNIVERSITATEA „SAPIENTIA” din CLUJ-NAPOCA
Facultatea de Științe Tehnice și Umaniste din Târgu Mureș
Programul de studii: **Calculatoare**

Viza facultății:



LUCRARE DE DIPLOMĂ

Coordonator științific:
Prof. univ. dr. ing. Dr. habil. Szilágyi László

Candidat: **Balázs Ákos**
Anul absolvirii: **2026**

a) Tema lucrării de licență:

CLASIFICAREA IMAGINILOR ROENTGEN DE PLĂMÂNI CU AJUTORUL REȚELELOR NEURONALE CU ÎNVĂȚARE PROFUNDĂ

b) Problemele principale tratate:

- Studiu bibliografic privind utilizarea rețelelor neuronale convoluționale (CNN) în imagistica medicală.
- Analiza și atenuarea fenomenului de „domain shift” prin tehnici cross-dataset (Mooney și COVID-19).
- Proiectarea unui pipeline de preprocesare: decupare asimetrică și îmbunătățirea contrastului prin CLAHE.
- Realizarea a 14 experimente iterative pentru optimizarea hiperparametrilor și fuziunea datelor.
- Integrarea algoritmului Grad-CAM (XAI) pentru validarea vizuală a deciziilor modelelor.
- Optimizarea pragului de clasificare prin Grid Search pentru maximizarea metricii F1-score.

c) Desene obligatorii:

- Schema bloc a pipeline-ului de preprocesare (Decupare + CLAHE + Augmentare).
- Diagrama fluxului de date și arhitectura sistemului software.
- Matricele de confuzie și curbele ROC-AUC ale modelelor optimizate.
- Vizualizări și hărți termice comparative generate de algoritmul Grad-CAM.

d) Softuri obligatorii:

- Aplicația web interactivă realizată în Python, utilizând framework-urile TensorFlow / Keras, OpenCV și Streamlit pentru inferență în timp real.

e) Bibliografia recomandată:

- Goodfellow, I., et al., Deep Learning, MIT Press, 2016.
- Selvaraju, R. R., et al., Grad-CAM, IEEE ICCV, 2017.
- Soomro, T. A., et al., Medical Image Analysis: A Review, CMPB, 2019.

f) Termene obligatorii de consultații: săptămânal

g) Locul și durata practicii: Universitatea „Sapientia” din Cluj-Napoca,
Facultatea de Științe Tehnice și Umaniste din Târgu Mureș

Primit tema la data de: 26.05.2025

Termen de predare: 29.06.2026

Semnătura Director Departament



Semnătura coordonatorului



Semnătura responsabilului
programului de studii



Semnătura candidatului



Declarație

Subsemnatul/a**BALAZS AKOS**....., absolvent(ă) al/a programului de studii **Calculatoare**, promoția**2026**..... cunoscând prevederile Legii Educației Naționale 199/2023 și a Codului de etică și deontologie profesională al Universității Sapientia cu privire la furtul intelectual declar pe propria răspundere că prezenta lucrare de licență/proiect de diplomă/disertație se bazează pe activitatea personală, cercetarea/proiectarea este efectuată de mine, informațiile și datele preluate din literatura de specialitate sunt citate în mod corespunzător.

Localitatea, **TÂRGU MUREȘ**
Data: **12.08.2026**

Absolvent
Semnătura.....**Balazs**.....

Extras

Evaluarea automatizată a radiografiilor toracice joacă un rol crucial în creșterea eficienței diagnosticării clinice și în reducerea volumului de muncă al medicilor radiologi. Scopul acestei lucrări de licență este proiectarea și implementarea unui sistem robust de procesare și clasificare a imaginilor bazat pe învățare profundă, capabil să diferențieze în mod fiabil cazurile sănătoase (NORMAL) de cele cu pneumonie (PNEUMONIA) din imagini radiologice digitale.

În cadrul cercetării, am realizat un proces iterativ sistematic compus din paisprezece faze experimentale. După stabilirea unui punct de referință prin dezvoltarea unei rețele neuronale convoluționale (CNN) personalizate, antrenate de la zero, am examinat și comparat microbial cinci arhitecturi pre-antrenate pe setul de date ImageNet (ResNet50, DenseNet121, EfficientNetB0, MobileNetV2, VGG16), aplicând o strategie de învățare prin transfer în două faze. Pe lângă reglarea fină (fine-tuning), s-a acordat o atenție deosebită metodelor specifice procesării de imagini medicale: dezechilibrul claselor a fost gestionat prin ponderarea claselor, în timp ce supra-antrenarea (overfitting) a fost combătută printr-o strategie strictă de augmentare a datelor, adaptată realităților anatomice.

În timpul testărilor, a fost identificat fenomenul de degradare a performanței cauzat de deplasarea domeniului (domain shift) atunci când modelele au întâlnit date clinice din surse necunoscute. Pentru a rezolva această problemă, am introdus egalizarea adaptivă a histogramei limitată prin contrast (CLAHE) în spațiul de culoare LAB, optimizarea pragului de clasificare prin căutare pe grilă (grid search) pentru maximizarea scorului F1 și o fuziune personalizată a seturilor de date (combinând bazele de date Mooney și COVID-19 Radiography), obținând un progres major în capacitatea de generalizare. Configurația VGG16 Combined a atins performanța maximă a proiectului, cu o acuratețe globală de 99,11% și o valoare ROC-AUC de 0,9984. Feabilitatea implementării pe dispozitive periferice a fost demonstrată de modelul MobileNetV2 Combined, care a oferit o acuratețe clinică relevantă de 97,33%, având un număr drastic redus de parametri.

Pentru a crește transparența, am integrat vizualizarea prin hărți termice Grad-CAM, care soluționează problema de tip „cutie neagră” a învățării profunde, oferind o explicabilitate vizuală a deciziilor. În cele din urmă, pentru demonstrarea în timp real a modelelor antrenate, am proiectat și realizat o aplicație web interactivă de prototip clinic utilizând framework-ul Streamlit.

Cuvinte cheie: învățare profundă, rețele neuronale convoluționale, învățare prin transfer, diagnosticarea pneumoniei, domain shift, Grad-CAM, Streamlit

SAPIENTIA ERDÉLYI MAGYAR
TUDOMÁNYEGYETEM
MAROSVÁSÁRHELYI KAR
SZÁMÍTÁSTECHNIKA SZAK



UNIVERSITATEA
SAPIENTIA
Facultatea de Științe Tehnice și
Umaniste din Târgu-Mureș

Tüdőröntgen felvételek osztályozása
mélytanulású neurális hálózatokkal

DIPLOMADOLGOZAT

Témavezető:

Dr. habil. Szilágyi László

Végzős hallgató:

Balázs Ákos

Kivonat

A mellkasröntgen-felvételek automatizált kiértékelése kulcsfontosságú szerepet játszik a klinikai diagnosztika hatékonyságának növelésében és a radiológusok munkaterhelésének csökkentésében. A diplomamunka célja egy olyan robusztus, mély tanuláson alapuló képfeldolgozó és osztályozó rendszer kifejlesztése, amely képes a digitális tüdőröntgen-felvételekről megbízhatóan elkülöníteni az egészséges (NORMAL) és a tüdőgyulladásos (PNEUMONIA) eseteket.

A kutatás során egy szisztematikus, tizennégy kísérleti fázisból álló iteratív folyamatot valósítottam meg. Egy saját tervezésű, nulláról betanított Baseline konvolúciós neurális hálózat (CNN) létrehozása után öt különböző, ImageNet adathalmazon előtanított architektúrát (ResNet50, DenseNet121, EfficientNetB0, MobileNetV2, VGG16) vizsgáltam és hasonlítottam össze a kétfázisú transzfer tanulás módszertanát alkalmazva. A modellek finomhangolása mellett nagy hangsúlyt fektettem az orvosi képfeldolgozás speciális eljárásaira: az osztályegyensúlytalanságot osztálysúlyok bevezetésével kezeltem, míg a túlilleszkedést szigorú, az anatómiai realitásokhoz igazított adataugmentációs stratégiával szorítottam vissza.

A tesztelések során azonosítottam a tartomány-eltolódás (domain shift) teljesítményromboló jelenségét, amikor a modellek ismeretlen forrásból származó klinikai adatokkal találkoztak. A probléma feloldására bevezettem a LAB-szintéren végrehajtott CLAHE kontraszt-kiegyenlítést, az osztályozási küszöbök rácskeresésen alapuló F1-score maximalizálását, valamint egy egyedi adatkészlet-fúziót (Mooney és COVID-19 Radiography adatbázisok kombinálása), amely áttörést hozott a modellek általánosító képességében. A projekt csúcsteljesítményét nyújtó VGG16 Combined konfiguráció 99,11%-os globális pontosságot és 0,9984-es ROC-AUC értéket ért el. A gyakorlati megvalósíthatóságot a MobileNetV2 Combined modell igazolta, amely drasztikusan alacsony paraméterszám mellett is klinikailag releváns, 97,33%-os pontosságot nyújtott.

A transzparencia növelése érdekében Grad-CAM hőterképes vizualizációt integráltam, amely feloldja a mélytanulás „fekete doboz” problémáját, és vizuálisan magyarázhatóvá teszi a döntéshozatalt. Végezetül a betanított modellek valós idejű demonstrálására egy interaktív Streamlit klinikai prototípus webalkalmazást terveztem és valósítottam meg.

Kulcsszavak: mély tanulás, konvolúciós neurális hálózatok, transzfer tanulás, tüdőgyulladás diagnosztika, domain shift, Grad-CAM, Streamlit

Abstract

Automated evaluation of chest X-ray images plays a crucial role in enhancing clinical diagnostic efficiency and mitigating radiologist workload. This thesis aims to design and implement a robust deep learning-based image processing and classification framework capable of reliably differentiating between healthy (NORMAL) and pneumonia-infected (PNEUMONIA) digital chest radiographs.

The research follows a systematic, iterative process consisting of fourteen distinct experimental phases. After establishing a referential baseline by developing a custom Convolutional Neural Network (CNN) trained from scratch, five prominent state-of-the-art architectures pre-trained on the ImageNet dataset (ResNet50, DenseNet121, EfficientNetB0, MobileNetV2, and VGG16) were evaluated and compared using a two-phase transfer learning methodology. Alongside fine-tuning, specific medical image processing techniques were prioritized: class imbalance was managed via class weights, while overfitting was suppressed using a strict, anatomically realistic data augmentation strategy.

During cross-validation, the performance-degrading effects of the domain shift phenomenon were observed when models encountered clinical data from unseen sources. To alleviate this, Contrast Limited Adaptive Histogram Equalization (CLAHE) in the LAB color space, grid-search-driven classification threshold optimization maximizing the F1-score, and a custom dataset fusion combining the Mooney and COVID-19 Radiography databases were introduced, delivering a breakthrough in generalization capability. The peak performance was achieved by the VGG16 Combined configuration, yielding a global accuracy of 99.11% and an ROC-AUC of 0.9984. Edge-device feasibility was demonstrated by the MobileNetV2 Combined model, which achieved a clinically relevant 97.33% accuracy with a drastically reduced parameter count.

To enhance transparency, Grad-CAM heatmap visualization was integrated to mitigate the "black box" nature of deep learning, making the model predictions explainable. Finally, an interactive Streamlit clinical prototype web application was designed and deployed to demonstrate the trained models in real-time.

Keywords: Deep Learning, Convolutional Neural Networks, Transfer Learning, Pneumonia Diagnosis, Domain Shift, Grad-CAM, Streamlit

Tartalomjegyzék

Ábrák jegyzéke	5
Táblázatok jegyzéke	6
Kódrészletek jegyzéke	7
1. Bevezetés	8
2. Elméleti háttér	10
2.1. Konvolúciós neurális hálózatok	10
2.1.1. A konvolúciós réteg	10
2.1.2. Pooling és regularizáció	10
2.2. Transfer learning (Transzfer tanulás)	11
2.2.1. Kétfázisú tanítási stratégia	11
2.2.2. Alkalmazott előtanított architektúrák	11
2.3. Orvosi képfeldolgozás speciális módszerei	13
2.3.1. Osztályegyensúlytalanság kezelése	13
2.3.2. Adataugmentációs stratégia	13
2.3.3. CLAHE kontraszt-egyenlítés	14
2.3.4. Osztályozási küszöb optimalizáció	14
2.3.5. Grad-CAM – modell magyarázhatóság	15
2.3.6. Domain shift jelensége	15
3. Adatkészletek, rendszer-specifikáció és módszertan	17
3.1. Felhasznált adatkészletek leírása	17
3.1.1. Chest X-Ray Images (Pneumonia)	17
3.1.2. COVID-19 Radiography Database	17
3.1.3. Kombinált adatkészlet (Combined Dataset)	18
3.2. A szoftveres fejlesztői környezet	18
3.3. A projekt saját alapmodelle (Baseline CNN)	18
4. Üzembe helyezés, kísérleti eredmények és mérések	20
4.1. Kísérleti fázisok és az előtanított modellek eredményei	20
4.1.1. ResNet50 eredményei	20

4.1.2.	DenseNet121 eredményei	21
4.1.3.	EfficientNetB0 eredményei	23
4.1.4.	MobileNetV2 eredményei	24
4.1.5.	VGG16 ($t = 0,5$) eredményei	25
4.2.	A VGG16 architektúra iteratív optimalizációja és a pipeline evolúciója	27
4.2.1.	Fázis 2: Szisztematikus döntési küszöb optimalizáció	27
4.2.2.	Fázis 3: LAB szintér alapú CLAHE kontraszt-egyenlítést alkalmazó VGG16 pipeline	28
4.2.3.	Fázis 4: Mesterséges intelligencia alapú tüdőszegmentációt alkalmazó kétszintű pipeline	30
4.2.4.	Fázis 5: Determinisztikus aszimmetrikus center crop és CLAHE előfeldolgozási pipeline	31
4.2.5.	Fázis 6: A véglegesített pipeline adaptációja a COVID-19 Radiography adatkészletre	34
4.3.	Kereszt-adatkészlet (Cross-Dataset) validáció és a Domain Shift számszerűsítése	35
4.4.	Transzfer tanulás kombinált, diverzifikált adatkészleten	37
4.4.1.	VGG16 + crop + CLAHE eredményei kombinált adatkészleten .	37
4.4.2.	MobileNetV2 + crop + CLAHE eredményei kombinált adatkészleten	39
4.5.	Az eredmények globális kiértékelése és konklúzió	41
5.	A klinikai prototípus webalkalmazás fejlesztése	43
5.1.	Követelmény-specifikáció és tervezés	43
5.1.1.	Felhasználói szerepkörök	44
5.1.2.	Funkcionális és nem funkcionális követelmények	45
5.1.3.	A rendszer használati esetei (Use Case)	46
5.2.	Főbb funkcionális modulok	47
5.3.	Rendszerarchitektúra és adatáramlás	48
5.4.	Modellkezelés és erőforrás-optimalizálás	50
5.5.	Intelligens, dinamikus előfeldolgozási réteg	51
5.6.	A Grad-CAM hő térkép szoftveres generálása	52
5.7.	A rendszer mappaszerkezete és komponensei	53
5.8.	A rendszer online elérhetősége	54
6.	Összegzés és jövőbeli irányok	55
6.1.	Jövőbeli fejlesztési irányok	56
	Irodalomjegyzék	57

Ábrák jegyzéke

4.1.	A ResNet50 modell teljesítményének részletes kiértékelése a teszt-halmazon	21
4.2.	A DenseNet121 modell teljesítményének részletes kiértékelése a teszt-halmazon	22
4.3.	Az EfficientNetB0 modell teljesítményének részletes kiértékelése a teszt-halmazon	23
4.4.	A MobileNetV2 modell teljesítményének részletes kiértékelése a teszt-halmazon	25
4.5.	A VGG16 ($t = 0,5$) modell teljesítményének részletes kiértékelése a teszt-halmazon	26
4.6.	A VGG16 (optimalizált threshold) modell teljesítményének kiértékelése	28
4.7.	A VGG16 + CLAHE modell teljesítményének részletes kiértékelése . .	29
4.8.	A VGG16 + U-Net + CLAHE modell teljesítményének részletes kiértékelése	31
4.9.	A determinisztikus előfeldolgozási pipeline blokkdiagramja	32
4.10.	Az aszimmetrikus center crop és CLAHE előfeldolgozás vizuális ellenőrzése (sanity check)	32
4.11.	A VGG16 + aszimmetrikus crop + CLAHE modell teljesítményének kiértékelése	33
4.12.	A VGG16 + crop + CLAHE (COVID adatkészlet) modell teljesítményének kiértékelése	35
4.13.	A VGG16 modellek kereszt-adatkészletes (Cross-Dataset) teljesítményének összehasonlító diagramja	37
4.14.	A VGG16 + crop + CLAHE modell konfúziós mátrixa és ROC görbéje a kombinált teszt-halmazon	39
4.15.	A MobileNetV2 + crop + CLAHE modell konfúziós mátrixa és ROC görbéje a kombinált teszt-halmazon	40
5.1.	A klinikai prototípus webalkalmazás használati eset (use-case) diagramja	46
5.2.	A webalkalmazás interaktív statisztikai irányítópultja (Model Statistics fül)	47
5.3.	A valós idejű diagnosztikai modul működés közben a Grad-CAM hőképpel kiegészítve	48
5.4.	A webalkalmazás belső adatáramlási és feldolgozási szekvenciadiagramja	49

Táblázatok jegyzéke

3.1. A Baseline CNN modell osztályozási eredményei a teszhalmazon . . .	19
4.1. A ResNet50 modell részletes osztályozási metrikái	20
4.2. A DenseNet121 modell részletes osztályozási metrikái	22
4.3. A EfficientNetB0 modell részletes osztályozási metrikái	23
4.4. A MobileNetV2 modell részletes osztályozási metrikái	24
4.5. A VGG16 ($t = 0,5$) modell részletes osztályozási metrikái	26
4.6. A VGG16 (optimalizált threshold) modell részletes osztályozási metrikái	27
4.7. A VGG16 + CLAHE modell részletes osztályozási metrikái	29
4.8. A VGG16 + U-Net + CLAHE modell részletes osztályozási metrikái . .	30
4.9. A VGG16 + aszimmetrikus crop + CLAHE modell részletes osztályozási metrikái	33
4.10. A VGG16 + crop + CLAHE (COVID-19 adatkészlet) modell részletes osztályozási metrikái	34
4.11. Kereszt-adatkészlet (Cross-Dataset) kiértékelési mátrix	36
4.12. A VGG16 + crop + CLAHE (Kombinált adatkészlet) modell részletes osztályozási metrikái	38
4.13. A MobileNetV2 + crop + CLAHE (Kombinált adatkészlet) modell osz- tályozási metrikái	40
4.14. A megvalósított modellek és előfeldolgozási konfigurációk összesített össze- hasonlítása	41
5.1. Felhasználói szerepkörök és elvárások specifikációja	44
5.2. Funkcionális és nem funkcionális követelmények mátrixa	45

Kódrészletek jegyzéke

5.1. A modellek hatékony betöltése és gyorsítótárazása	50
5.2. A dinamikus és automatizált előfeldolgozási logika	51
5.3. A Grad-CAM hő térkép matematikai levezetése és implementációja . . .	53

1. fejezet

Bevezetés

A mellkasröntgen-felvétel az egyik legelterjedtebb valamint legköltséghatékonyabb képalkotó diagnosztikai eljárás, amelyet klinikai gyakorlatban számos betegségek diagnosztizálására használnak (tüdőgyulladás, tuberkulózis, daganatos elváltozások és egyéb mellkasi betegségek felismerése). Tekintve, hogy világszerte évente akár több százmillió mellkasröntgen-felvétel készül, ezeknek a kiértékelése nem kis feladat és több tényezőtől is függ beleértve a radiológus szakember tapasztalatát, munkaterhelését, ébrenléti állapotát. Az alacsony és közepes jövedelmű országokban, ahol korlátozottabb számú szakképzett radiológus van jelen, ez a probléma sokkal inkább fennáll és emiatt gyakrabban fordulnak elő komoly diagnosztikai késlekedések valamint a téves diagnózisok száma is magasabb.

A mélytanulás (deep learning) és ezen binnen a konvolúciós neurális hálózatok (CNN - Convolutional Neural Networks) jelentősen felgyorsították ezeket a folyamatokat, forradalmasítva az orvosi képelemzés számos területeit. Az AlexNet 2012-es győzelme az ImageNet Large Scale Visual Recognition Challenge versenyen [1] remekül megmutatja, hogy a mélytanulású modellek képesek megközelíteni vagy akár esetenként felülmúlni az emberi teljesítményt vizuális osztályozási feladatokban. Ez a felismerés gyorsan utat talált az orvosi képdiagnosztika területére is.

Diplomamunkám célja a mellkasröntgen-felvételek eredményes osztályozása mélytanulású neurális hálózatok segítségével. A rendszernek a bemeneti képből meg kell állapítania, hogy az egészséges tüdőt (*NORMAL*) vagy tüdőgyulladásos tüdőt (*PNEUMONIA*) ábrázol-e. A projekt célja nem egyetlen "végső" modell kidolgozása van, hanem a fejlesztési folyamat és kísérleteim szisztematikus dokumentálásán mindeközben törekedve, hogy a lehető legjobb és leghasznosabb eredményeket érjek el minden egyes kísérletemmel. Egy egyszerűbb alap modellből kiindulva fokozatosan összetettebb kísérleteket hajtottam végre és különböző architektúrával rendelkező transzfer-tanuláson alapuló neurális hálózatot is kipróbáltam, melyeket összehasonlítottam, kiértékeltem és módosításokat vittem végbe rajtuk, hogy a lehető legjobban teljesítsenek. A projekt megvalósítása során több valós problémával is szembesültem, amik lehetővé tették, hogy ne csak gépiesen ugyanazt a folyamatot ismételjem minden egyes architektúra

bevezetésénél, hanem fókuszáljak a háttérbeli folyamatokra is. Tanulmányoztam a hálózatok működését, a feldolgozási folyamatokat, and megpróbáltam nem egy "fekete dobozként" tekinteni a rendszerre.

A dolgozat a következő fő kérdésekre keresi a választ. Egy viszonylag egyszerű, nul-láról betanított konvolúciós hálózat mennyire képes jó eredményeket elérni tüdőrontgen-osztályozási feladatban? Hogyan tudja a transzfer tanulás javítani az eredményeket az alapmodellhez képest, és az alkalmazott előtanított architektúrák közül melyik az amelyik a legjobban helytáll ebben a feladatban? Milyen előfeldolgozási és döntési stratégi-ák (CLAHE kontraszt-kiegyenlítés, osztályozási küszöb optimalizáció, bemeneti képek szegmentációja/croppolása) növelhetik tovább a modellek teljesítményét és általánosító képességét főképp idegen adatokon? Hogyan értelemezhető és magyarázható a model-lek döntéshozatala Grad-CAM vizualizáció segítségével [11]? Hogyan integrálhatóak a betanított modellek egy klinikai prototípus webalkalmazás keretén belül?

A dolgozat felépítése a következő: a második fejezet az elméleti háttérrel tárgyalja (konvolúciós hálózatok, transzfer tanulás, CLAHE, Grad-CAM, domain shift jelenség); a harmadik fejezet a tanításhoz használt adatkészleteket és az általános módszertant ismerteti; a negyedik fejezet a megvalósított kísérleteket és azok eredményeit mutatja be modelltől modellre; az ötödik fejezet a kifejlesztett Streamlit webalkalmazást írja le; a hatodik fejezet összegzi a tanulságokat és a jövőbeli fejlesztési irányokat.

2. fejezet

Elméleti háttér

2.1. Konvolúciós neurális hálózatok

A konvolúciós neurális hálózatok (CNN) olyan mélytanulási architektúrák, amelyeket kifejezetten képfeldolgozási feladatokra terveztek. Alapötletük a biológiai látókéregből merít: a rácsos elrendezésű adatok (képek, hangspektrumok) feldolgozásához lokális receptív mezőket alkalmaznak, amelyek a paramétermegosztás elvének köszönhetően lényegesen kevesebb tanulható súlyt igényelnek, mint a hagyományos, teljesen összekötött (fully connected) hálózatok.

2.1.1. A konvolúciós réteg

Egy konvolúciós réteg bemenete egy $H \times W \times C$ méretű tenzor (magasság, szélesség, csatornák száma). A réteg K darab, $k \times k \times C$ méretű szűrőt (filtert) tartalmaz, amelyek végigcsúsznak a bemeneten. Az i -edik szűrő kimenete (feature map) az alábbi diszkrét konvolúcióval számítható:

$$S_i(x, y) = \sum_{c=1}^C \sum_{u=0}^{k-1} \sum_{v=0}^{k-1} I(x+u, y+v, c) \cdot W_i(u, v, c) + b_i \quad (2.1)$$

ahol I a bemeneti tenzor, W_i az i -edik szűrő súlymátrixa, b_i pedig az eltolás (bias) tagja. A konvolúció után általában nemlineáris aktivációs függvényt alkalmaznak; a leggyakoribb a ReLU ($f(x) = \max(0, x)$) aktivációs függvény [7], amely egyszerűsége és gradiensmegőrző tulajdonsága miatt vált széles körben elterjedtté.

2.1.2. Pooling és regularizáció

A konvolúciós blokkok után jellemzően pooling réteg következik, amely a feature map méretét csökkenti és ezzel térinvariáns reprezentációt hoz létre. A maximális pooling (max pooling) egy $p \times p$ -es ablakban a maximális értéket tartja meg, ezzel az aktiválások legdominánsabb jellemzőit őrzi meg.

Az overfitting visszaszorítására a konvolúciós neurális hálózatokban leggyakrabban alkalmazott technika a Dropout: tanítás közben a neuronok egy véletlen d arányú hányadát ideiglenesen „kikapcsolják” (kimenetüket nullára állítják) [8], ami arra kényszeríti a hálózatot, hogy redundáns, egymást kiegészítő reprezentációkat tanuljon. A Batch Normalization rétegek [9] a minibatch aktivációinak normalizálásával stabilizálják és gyorsítják a tanítást.

2.2. Transfer learning (Transzfer tanulás)

A transzfer tanulás azon az elven alapul, hogy egy adott modell már előre van tanítva egy nagyobb adatkészleten (tipikusan az ImageNet-en) elsajátítva alacsony és közepes szintű jellemzőket - élek, textúrák, alakzatok - és ezáltal különböző vizuális feladatokra is felhasználhatóak. Az orvosi felvételeket tekintve ez a megközelítés különösen fontos lehet, hiszen a magas minőségű annotált orvosi adatból általában lényegesen kevesebb áll rendelkezésünkre mint természetes képekből.

2.2.1. Kétfázisú tanítási stratégia

A jelen projektben alkalmazott kétfázisú megközelítés a következőképpen épül fel:

1. **Fagyasztott backbone fázis:** Az adott előtanított modell súlyait rögzítettem (frozen) és csak az újonnan hozzáadott osztályozó fejrégeket hagytam tanulni. Az optimalizáló tanulási ráta ebben az első fázisban 10^{-4} .
2. **Finomhangolási fázis (fine-tuning):** A backbone felső rétegeinek (jellemzően az utolsó 30-40 rétegnek) a súlyait feloldottam, és az egész hálózatot egy alacsonyabb tanulási rátán (10^{-5}) hagytam tovább tanulni. Ez lehetővé teszi, hogy az előtanított jellemzők a célfeladathoz igazodjanak.

Mindkét fázisban EarlyStopping, ReduceLROnPlateau és ModelCheckpoint visszahívókat (callbacks) alkalmaztam a tanítás stabilitásának és a legjobb modell megőrzésének érdekében.

2.2.2. Alkalmazott előtanított architektúrák

A kutatás során olyan ImageNet adatbázison előtanított modellek összehasonlítására törekedtem, amelyek reprezentálják a mélytanulású neurális hálózatok fejlődési mérföldköveit. A portfólió kialakításakor fontos szempont volt, hogy a robusztus, klasszikus struktúráktól kezdve a kifejezetten erőforrás-hatékony, mobil környezetre tervezett architektúrákig vizsgáljam a tüdőbetegségek felismerési hatékonyságát.

ResNet50. A He és munkatársai által bevezetett ResNet50 architektúrát [2] a tüdődiagnosztikában a reziduális kapcsolatok (skip connection-ök) nyújtotta stabilitás indokolja. Mivel a mellkasröntgeneken látható patológiás elváltozások – mint például a tüdőgyulladásos infiltrátumok – gyakran rendkívül finom, elmosódott szürkeárnyalatos textúraváltozásként jelentkeznek, azonosításukhoz mély architektúrára van szükség. A hálózat a blokkokon belüli $F(x) + x$ alakú matematikai leképezéssel küszöböli ki a mély struktúráknál kritikus gradiens-eltűnési problémát. Az így létrejövő ≈ 25 millió paraméteres modell képes megőrizni a korai rétegekben detektált alapvető anatómiai kontúrokat (pl. a bordák vagy a rekeszizom ívei), miközben komplex szemantikai jegyeket tanul meg, így az orvosi képfeldolgozásban megbízható baseline-ként szolgál.

DenseNet121. A Huang és társai nevéhez fűződő DenseNet121 architektúra [3] alapjaiban tér el a hagyományos szekvenciális modellektől: itt minden egyes réteg közvetlen kapcsolatban áll az összes öt megelőző réteg jellemzőtérképével. Ez a sűrű feature-újrahasznosítási mechanizmus különösen előnyös a tüdőröntgenek elemzésekor, ahol a különböző elváltozások (például a tüdőgócok vagy a légmell) mérete és térbeli elhelyezkedése rendkívül heterogén. Az alacsony és magas szintű vizuális jegyek folyamatos kombinációja révén a hálózat kiemelkedő reprezentációs képességgel bír, ráadásul a redundáns paraméterek elhagyásával a méretéhez képest rendkívül kompakt, mindössze ≈ 8 millió paramétert számlál. Hatékonyságát az is igazolja, hogy a klinikai AI-kutatások egyik alapköve, a CheXNet is erre a struktúrára épül.

EfficientNetB0. A Tan és Le által kidolgozott EfficientNetB0 [4] bevonását a strukturális optimalizáltsága indokolja. A hálózat az úgynevezett compound scaling elv mentén működik, amely együttesen, egy fix együttható alapján skálázza a modell mélységét, szélességét és a bemeneti képfelbontást. Az orvosi adathalmazok korlátozott mérete és gyakori kiegyensúlyozatlansága miatt a túlilleszkedés (overfitting) komoly kockázatot jelent; az EfficientNetB0 a maga $\approx 5,3$ millió paraméterével úgy képes minimalizálni ezt a veszélyt, hogy közben pontosságban felveszi a versenyt a lényegesen nagyobb, komplexebb hálózatokkal is.

MobileNetV2. A Sandler és munkatársai által fejlesztett MobileNetV2 [5] integrálásával egy gyakorlati, klinikai problémára kerestem a választ: hogyan teljesít egy diagnosztikai modell erőforrás-korlátos környezetben. Az architektúra a hagyományos konvolúciókat mélységi elválasztható konvolúciókra (depthwise separable convolutions) cseréli, valamint invertált reziduális blokkokat alkalmaz, aminek köszönhetően a paraméterszáma csupán $\approx 3,4$ millió. Ez az alacsony memória- és számítási igény elengedhetetlen az olyan valós alkalmazásokban, mint a telemedicina vagy a tüdőszűrő buszokon működő hordozható diagnosztikai eszközök, ahol a predikciónak lokálisan, korlátozott hardveren kell lefutnia.

VGG16. A Simonyan és Zisserman-féle VGG16 architektúra [6] a vizsgált modellek közül a leginkább hagyományos felépítésű, amely tisztán egymásra épülő, 3×3 -as konvolúciós blokkokból áll. Bár a modern skip connection-ök hiánya és a kimagaslóan nagy, 138 millió paraméteres mérete miatt számításigényes és hajlamos a túlilleszkedésre, a gyakorlati tesztek során rendkívül magas ROC–AUC értéket mutatott a tüdőrontgen-osztályozási feladaton. Ez a jelenség arra vezethető vissza, hogy a nagyméretű, sűrű konvolúciós szűrők képesek olyan kiterjedt, globális texturális mintázatokat (például: diffúz tüdőgyulladásos konszolidációkat) rögzíteni, amelyeket a modernebb, erősen tömörített hálózatok hajlamosak elhanyagolni. Kiváló osztályszeparációs képessége miatt ez az architektúra lett kijelölve a dolgozatban a további, részletes finomhangolásra, valamint minden módosítást ami az előfeldolgozást illeti azt ezen a hálózaton teszteltem.

2.3. Orvosi képfeldolgozás speciális módszerei

2.3.1. Osztályegyensúlytalanság kezelése

Az alkalmazott Chest X-Ray (Kaggle - Paul Mooney) adatkészletben a tanítóhalmazon belül a PNEUMONIA osztály közel háromszor annyi példányból áll, mint a NORMAL osztály (3875 vs. 1341 kép). Az ilyen osztályegyensúlytalanság hatására a modell hajlamos a többségi osztály felé torzítani, ami a NORMAL osztály felismerési arányának romlásához vezet.

A kiegyensúlyozatlanság kezelésére osztálysúlyokat (class weights) alkalmaztam, amelyek a tanítás során a ritka osztályhoz tartozó minták veszteségét felnagyítják:

$$w_c = \frac{N_{\text{total}}}{2 \cdot N_c} \quad (2.2)$$

ahol N_{total} a tanítóhalmaz összes elemének száma, N_c pedig a c -edik osztályhoz tartozó minták száma. Ennek eredményeként a NORMAL osztálysúlya $\approx 1,94$, a PNEUMONIA osztályé $\approx 0,67$ lett.

2.3.2. Adataugmentációs stratégia

A mély tanuló modellek robusztusságának növelése és a túlilleszkedés (overfitting) megakadályozása érdekében adataugmentációs eljárást alkalmaztam. Kulcsfontosságú módszertani lépés, hogy a geometriai transzformációk kizárólag a tanító adathalmazra korlátozódtak, míg a validációs és tesztelési fázisok során a képek az eredeti, módosítatlan formájukban kerültek a hálózat elé, biztosítva ezzel a modellek valós teljesítményének torzításmentes kiértékelését.

Az augmentációs folyamat során alkalmazott térbeli transzformációk paramétereit szigorúan a klinikai realitásokhoz igazítottam, elkerülve az olyan drasztikus torzításokat, amelyek sérthetnék a radiológiai felvételek anatómiai értelmezhetőségét. Ennek

megfelelően a képeken $\pm 10^\circ$ -os kontrollált tartományon belüli véletlenszerű elforgatást, maximálisan $\pm 10\%$ -os léptékű nagyítást (zoom), valamint mind vízszintes, mind függőleges irányban legfeljebb $\pm 6\%$ -os eltolást engedélyeztem. Ezek a módosítások hatékonyan modellezik a páciensek vizsgálat közbeni kismértékű elmozdulásait, a pozicionálási pontatlanságokat, valamint a testalkatból adódó méretbeli eltéréseket.

Bár a számítógépes látásban a vízszintes tükrözés (horizontal flip) az egyik legelterjedtebb adataugmentációs technika, a fejlesztés korai szakaszában hozott módszertani döntés alapján ezt a transzformációt teljesen kiiktattam a csatornából. A mellkasröntgenek esetében a belső szervek aszimmetrikus elhelyezkedése – különös tekintettel a szív balra orientált anatómiájára és a mediastinum struktúrájára – determinisztikus jelentőséggel bír. A horizontális tükrözés alkalmazása olyan anatómiailag hibás, a valóságban ritka anomáliának megfelelő (például dextrocardia vagy situs inversus) képkonfigurációkat hozott volna létre, amelyek hamis térbeli mintázatok elsajátítására kényszerítették volna a modellt, ezáltal rontva a specifikus tüdőpatológiák felismerésének hatékonyságát.

2.3.3. CLAHE kontraszt-egyenlítés

A Contrast Limited Adaptive Histogram Equalization (CLAHE) [10] az adaptív hisztogram-egyenlítés egy korlátozott változata, amelyet eredetileg orvosi képfeldolgozásra fejlesztettek ki. A hagyományos hisztogram-egyenlítéssel szemben a CLAHE a képet kis, egymással átfedő blokkokra (tile-okra) osztja, és minden blokkon belül külön végzi az egyenlítést, miközben egy vágási küszöb (clip limit) megakadályozza a zajamplifikációt.

A projektben a CLAHE alkalmazásának motivációja a *domain shift* jelenség méréséklése volt. A különböző kórházakban, különböző berendezésekkel és protokollokkal készített röntgenfelvételek expozíciója, kontrasztja és fényereje eltérhet a tanítóhalmaz jellemzőitől. A CLAHE normalizálja ezeket az eltéréseket, segítve ezzel, hogy a modell ne csupán a saját adatkészletén, hanem ismeretlen forrású képeken is megbízható teljesítményt nyújtson.

A megvalósítás során a képeket LAB színtérbe konvertáltam (ahol az L csatorna a luminanciát reprezentálja), majd csak az L csatornára alkalmaztam a CLAHE eljárást, végül a képeket visszakonvertáltam RGB formátumba a modellnek megfelelő előfeldolgozással.

2.3.4. Osztályozási küszöb optimalizáció

A legtöbb bináris osztályozó alapértelmezés szerint 0,5-ös döntési küszöböt alkalmaz. Az orvosi diagnosztika területén azonban a küszöb megválasztása klinikai szempontból kritikus kompromisszumot jelent az érzékenység (sensitivity, PNEUMONIA recall) és a specificitás (specificity, NORMAL recall) között.

A VGG16 modell alapértelmezett küszöb mellett rendkívül magas PNEUMONIA

recall értéket ért el (98,72%), azonban a NORMAL osztályban jelentős számú tévesen pozitív predikciót produkált. A küszöb optimalizáció az alábbi lépésekből állt:

1. A modell szigmoid kimenetének küszöbölésével bináris előjelzések generálása a validációs halmazon 0,3-tól 0,7-ig terjedő, 0,01 lépéses rácskeresés mellett.
2. Az optimális küszöb meghatározása az F1-score maximalizálása alapján, figyelembe véve a klinikai prioritásokat.
3. Az így meghatározott küszöb alkalmazása a teszt halmaz kiértékelésénél.

2.3.5. Grad-CAM – modell magyarázhatóság

A mélytanulású neurális hálózatok esetében nehezen értelmezhető emberi szemmel a döntéshozatal folyamata, ami orvosi diagnosztizálás esetében különösen problematikus. A Grad-CAM (Gradient-weighted Class Activation Mapping) módszer [11] ezt az úgynevezett "fekete doboz" problémát hivatott kezelni. Szerettem volna látni, hogy miképpen vizualizálja ez a módszer a modell döntéseit ezáltal megértve, hogy melyek azok a területek az adott felvételen amik a tényleges elváltozást ábrázolják.

A Grad-CAM az osztályozási döntéshez leginkább hozzájáruló képrégiók azonosítására az utolsó konvolúciós réteg aktivációinak gradienseit számítja:

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k} \quad (2.3)$$

ahol y^c a c -edik osztály szigmoid kimenete, A^k a k -edik feature map, Z pedig a feature map elemeinek száma (normalizáló faktor). A hő térkép (heatmap) az aktivációk súlyozott összege:

$$L_{\text{Grad-CAM}}^c = \text{ReLU} \left(\sum_k \alpha_k^c \cdot A^k \right) \quad (2.4)$$

Az így kapott hő térképet az eredeti kép méretére nagyítottam, majd rávetítettem a bemeneti képre. A meleg színekkel jelölt területek (piros, sárga) ábrázolják a kép azon részeit amelyek leginkább befolyásolták az adott osztályba való sorolást.

A projektben alkalmazott Grad-CAM vizualizációval minden transzfer-tanuláson alapuló modellnél vizsgáltam, hogy a hálózat valóban a tüdő releváns anatómiai területeire fókuszál-e a döntéshozatala során. Ez a módszer nemcsak a modellek működésébe engedett betekintést, hanem rávilágított arra a problémára is, hogy a hálózatok sok esetben egyéb zavaró tényezők alapján döntöttek, ami éles használat esetén csökkenti a megbízhatóságukat.

2.3.6. Domain shift jelensége

A domain shift (tartomány-eltolódás) jelensége akkor lép fel, amikor egy modell tanítási és tesztelési adatai eltérő statisztikai eloszlásból származnak. Orvosi képfeldolgozásban

ez különösen gyakori: a különböző kórházak, gyártmányú készülékek és expozíciós protokollok mind hozzájárulnak ahhoz, hogy a valós klinikai körülmények között rögzített képek eltérjenek a tanítóhalmaz képeitől.

A jelen projektben a domain shift hatása jól megfigyelhető volt: a modelleket kizárólag a Kaggle Chest X-Ray Pneumonia adatkészletén tanítottam, és bár a saját teszthalmazon kiemelkedő eredményeket értek el (90% feletti pontosság), valós klinikai forrásból származó ismeretlen képeken – amelyeket a Streamlit webalkalmazás segítségével teszteltem – a teljesítmény jelentősen romlott.

3. fejezet

Adatkészletek, rendszer-specifikáció és módszertan

3.1. Felhasznált adatkészletek leírása

A kutatás és a kísérletek során két különböző, nyilvánosan elérhető tüdőrontgen adatkészletet, valamint ezek fúziójából egy harmadik, kombinált adatkészletet használtam fel.

A módszertan konzisztenciája érdekében a kutatás kezdeti fázisában – amikor az előtanított architektúrák összehasonlító elemzését végeztem – kizárólag ugyanazt az adathalmazt (3.1.1. Chest X-Ray Images) alkalmaztam a tanítási és tesztelési folyamatokhoz. Ez a megközelítés garantálta a kísérletek objektivitását és a modellek közötti összehasonlítás igazságosságát (fair comparison). A későbbiekben, amikor a kutatás fókuszába állított VGG16-os architektúrán vizsgáltam a különböző optimalizációs módosításokat, már bevezettem a COVID-19 Radiography Database adathalmazt is, hogy végre tudjam hajtani a kereszt-adatkészletes (cross-dataset) validációt a hálózaton.

3.1.1. Chest X-Ray Images (Pneumonia)

Ez az adatkészlet [12] (forrása: Paul Mooney, Kaggle) képezi az első tíz kísérlet gerincét. Összesen körülbelül 5216 darab binárisan annotált mellkasrontgen felvételt tartalmaz, amely *NORMAL* (egészséges) és *PNEUMONIA* (tüdőgyulladásos) osztályokra oszlik. Az adatkészlet gyárilag rögzített train, validation és test felosztással rendelkezik. Bár a pneumonia osztályon binnen a fájlnevek jelzik a megbetegedés bakteriális vagy vírusos eredetét, a projekt ezt tisztán bináris feladatként kezeli. Az adatkészlet jellegzetessége, hogy jelentős számban tartalmaz gyermekbetegekről készült felvételeket.

3.1.2. COVID-19 Radiography Database

A kereszt-adatkészletes (cross-dataset) validációhoz a Tawsifur Rahman által publikált adatbázist [13] használtam fel. A projekt céljainak megfelelően a *COVID* és *Lung Opa-*

city osztályokat teljesen kizártam a vizsgálatból, így kizárólag a *Normal* (10 192 kép) és a *Viral Pneumonia* (1345 kép) osztályokat emeltem át. Ez az adatkészlet felnőtt betegek felvételeit tartalmazza, és a Paul Mooney-féle adatkészlethez képest lényegesen homogénebb képminőséggel, valamint eltérő expozíciós karakterisztikákkal rendelkezik. Mivel nem tartalmazott gyári felosztást, stratifikált mintavétellel 80%/10%/10% arányban bontottam fel tanító-, validációs és tesztalmazra.

3.1.3. Kombinált adatkészlet (Combined Dataset)

A domain shift jelenség hatékony kezelésére egy egyedi integrációs szkriptet (`merge_datasets.py`) készítettem, amely a fenti két adatkészletet vonta össze. A súlyos osztályegyensúlytalanság kiküszöbölésére alulmintavételezést (undersampling) alkalmaztam: a *Normal* osztály méretét lecsökkentettem a *Pneumonia* osztály megengedett méretére. A létrejött kiegyensúlyozott adatkészlet összesen 11 236 képet tartalmaz (5618 egészséges és 5618 patológiás kép), amelyet szintén stratifikált 80%/10%/10% arányban osztottam fel.

Ez az osztályegyensúly-kezelés és fúzió rendkívül pozitív hatással volt a domain shift probléma feloldására, mivel az adathalmaz egyszerre fedte le a gyermekkori és felnőttkori anatómiai sajátosságokat, illetve a különféle kórházi géptípusokból adódó képi varianciát. Ennek a széles körű reprezentációnak köszönhetően a hálózat robusztussága jelentősen növekedett, és sokkal magabiztosabb, pontosabb predikciókat nyújtott az éles tesztelés során feltöltött, teljesen idegen felvételekre is.

3.2. A szoftveres fejlesztői környezet

A teljes architektúra implementációja és a modellek betanítása Python nyelven, TensorFlow és Keras környezetben történt, Kaggle Notebook infrastruktúrán, dedikált GPU gyorsítás mellett. Az adatelőkészítést és a pipeline-ok kezelését `pandas`, `OpenCV` (`opencv – python`), `Pillow` és `numpy` könyvtárak támogatták.

A fejlesztést jelentősen megkönnyítette, hogy a felhasznált forrásadatbázisok natívan elérhetőek a Kaggle platformon, így a modellek tréningje során közvetlenül, külső letöltési és tárolási korlátok nélkül tudtam hozzáférni a képekhez. A reprodukálhatóság és a későbbi hozzáférhetőség érdekében a projekt során általam generált, egyedi kombinált adatkészletet szintén feltöltöttem a platformra, így az a felhőalapú infrastruktúrán belül közvetlenül beágyazhatóvá vált a futtatási folyamatba.

3.3. A projekt saját alapmodelle (Baseline CNN)

A fejlesztés első lépéseként egy nulláról betanított (from-scratch) egyedi konvolúciós neurális hálózatot valósítottam meg. A hálózat feladata a teljes adatfeldolgozási pipeline technikai ellenőrzése és egy minimális referenciapont (baseline) biztosítása volt.

Architektúrája négy egymást követő konvolúciós blokkból áll, amelyek szűrőszámai progresszíven növekednek: 32, 64, 128, végül 256. Minden blokk magában foglal két egymás utáni 3×3 -as konvolúciós réteget, Batch Normalization-t, ReLU aktivációt, 2×2 -es Max Pooling réteget, valamint Dropout regularizációt. A konvolúciós jellemzőkinyerő részt egy teljesen összekötött osztályozó fej zárja le (256 majd 64 neuronnal, végül egy 2 osztályos szoftmax kimenettel).

Bár nem ez a saját architektúra határozza meg a projekt végső kimenetelét – hiszen abszolút értékben nem ért el kiemelkedő eredményeket –, a megvalósítása alapvető fontosságú volt a fejlesztés kezdetén. Kiváló gyakorlati kiindulópontot nyújtott a mély neurális hálózatok strukturális felépítésének, a rétegek egymáshoz kapcsolódásának és a hiperparaméterek hangolásának mélyebb megértéséhez.

Az alapmodell a 624 képet tartalmazó tesztalmazon 86,06%-os átfogó pontosságot (accuracy) ért el. Az osztályszintű metrikai mutatók részletes bontása az alábbi táblázatban látható:

3.1. táblázat. A Baseline CNN modell osztályozási eredményei a tesztalmazon

Osztály	Precision	Recall	F1-score	Support
NORMAL	0,8848	0,7222	0,7953	234
PNEUMONIA	0,8499	0,9436	0,8943	390
Accuracy			0,8606	624
Macro avg	0,8674	0,8329	0,8448	624
Weighted avg	0,8630	0,8606	0,8572	624

Az eredményekből jól látható, hogy a hálózat a pneumonia osztály esetében kiemelkedően magas szenzitivitást (recall: 0,9436) mutatott, ami orvosi szempontból kedvező, hiszen a betegek többségét sikeresen kiszűrte. Ugyanakkor az egészséges (NORMAL) képek esetében tapasztalható alacsonyabb felidézési arány (0,7222) arra utal, hogy a modell hajlamos volt a fals pozitív döntésekre, ami igazolta a komplexebb, transzfer-tanuláson alapuló architektúrák bevezetésének szükségességét.

4. fejezet

Üzembe helyezés, kísérleti eredmények és mérések

A dolgozat ezen fejezete bemutatja a lefolytatott 14 kísérleti fázist, a modellek fejlődési ívét, az alkalmazott optimalizációs lépéseket, valamint a kereszt-adatkészletes validáció eredményeit.

4.1. Kísérleti fázisok és az előtanított modellek eredményei

A kezdeti Baseline CNN után öt különböző, ImageNet-en előtanított hálózaton alkalmaztam a kétfázisú transzfer tanulást az alapértelmezett 0,5-ös döntési küszöb mellett.

4.1.1. ResNet50 eredményei

A kétfázisú transzfer tanulással finomhangolt ResNet50 architektúra teljesítményének számszerűsítésére a modellt a 624 mintából álló gyári teszhalmazon értékeltem ki. A hálózat az alapértelmezett 0,5-ös osztályozási küszöb mellett 86,54%-os globális pontosságot (accuracy) ért el. A modell részletes osztályszintű metrikai mutatóit a 4.1. táblázat foglalja össze.


4.1. táblázat. A ResNet50 modell részletes osztályozási metrikái

Osztály	Precision	Recall	F1-score	Support
NORMAL	0,8947	0,7265	0,8019	234
PNEUMONIA	0,8529	0,9487	0,8982	390
Macro Avg	0,8738	0,8376	0,8501	624
Weighted Avg	0,8685	0,8654	0,8621	624

A mérési eredmények alapján látható, hogy a modell megbízhatóan és magas érzékenységgel azonosította a tüdőgyulladásos eseteket, amit a 94,87%-os recall (szenzitivitás) érték is igazol. Ez orvosi szempontból kritikus fontosságú, hiszen a diagnosztikai

szoftvereknél a legfontosabb elvárás, hogy a valódi betegek ne maradjanak detektálatlanul.

Ugyanakkor a *NORMAL* osztályban tapasztalt alacsony, 72,65%-os recall komoly korlátokra utal. Ez a gyakorlatban azt jelenti, hogy az egészséges páciensek több mint 27%-át a hálózat tévesen tüdőgyulladásosnak minősítette. A háttérben meghúzódó osztályelrendezést a 4.1a. ábrán látható konfúziós mátrix szemlélteti.



4.1. ábra. A ResNet50 modell teljesítményének részletes kiértékelése a teszhalmazon

A konfúziós mátrix számszerű elemzése megmutatja, hogy a hálózat a 390 tüdőgyulladásos képből 370 esetet helyesen ismert fel (True Positive), és mindössze 20 mintát vétett el (False Negative). Ezzel szemben a 234 egészséges felvételtől 64 darabot tévesen a patológiás osztályba sorolt (False Positive), és csak 170 esetben hozott helyes döntést (True Negative).

Ez a jelenség arra vezethető vissza, hogy a Paul Mooney-féle adatkészlet jelentős részben gyermekorvosi felvételeket tartalmaz, ahol a fejlődésben lévő tüdő és a csecsemőmirigy (thymus) természetes szöveti sűrűsége a röntgenképeken fehér tónusú árnyékként jelenik meg. A ResNet50 mély konvolúciós szűrői ezeket a normális anatómiai struktúrákat a tüdőgyulladásra jellemző infiltrátumokként (konszolidációkként) értelmezték. Mivel az osztályozási határ az alapértelmezett 0,5-ös értéken állt, a modell rendkívül "óvatos", pneumonia-orientált viselkedést vett fel, ami a fals pozitív diagnózisok magas számát eredményezte.


4.1.2. DenseNet121 eredményei

A sűrűn összekötött konvolúciós hálózat (DenseNet121) kiértékelése ugyancsak a 624 mintát számláló gyári teszhalmazon történt. A modell az alapértelmezett küszöbszint mellett 89,74%-os globális pontosságot (accuracy) ért el, amellyel felülmúlta a ResNet50 teljesítményét. A hálózat részletes, osztályokra lebontott metrikai mutatóit a 4.2. táblázat foglalja össze.

4.2. táblázat. A DenseNet121 modell részletes osztályozási metrikái

Osztály	Precision	Recall	F1-score	Support
NORMAL	0,8795	0,8419	0,8603	234
PNEUMONIA	0,9073	0,9308	0,9189	390
Macro Avg	0,8934	0,8864	0,8896	624
Weighted Avg	0,8969	0,8974	0,8969	624

A mérési adatokból tisztán látszik, hogy a DenseNet121 lényegesen kiegyensúlyozottabb predikciós képességgel rendelkezik, mint a korábban vizsgált ResNet50. Bár a pneumonia osztály recall értéke minimálisan csökkent (93,08%), a *NORMAL* osztály recall mutatója drasztikus javulást mutatva elérte a 84,19%-ot. Ez a klinikai gyakorlatban azt jelenti, hogy az egészséges páciensek téves diagnosztizálásának aránya jelentősen visszaesett. A modell belső döntési eloszlását a 4.2a. ábrán látható konfúziós mátrix szemlélteti.



4.2. ábra. A DenseNet121 modell teljesítményének részletes kiértékelése a teszhalmazon

A konfúziós mátrix részletes vizsgálata megmutatja a javulás pontos dinamikáját: a hálózat a 390 tüdőgyulladásos felvételtől 363 esetet helyesen detektált (True Positive), és 27 mintát vétett el (False Negative). A legfőbb előrelépés azonban az egészséges osztályban történt, ahol a 234 normál röntgenképből 197 esetben hozott helyes döntést (True Negative), és a tévesen pozitívnak ítélt esetek számát sikerült 37-re redukálnia (False Positive).

Ez a strukturális fejlődés az architektúra sajátos felépítésére vezethető vissza. Mivel a DenseNet121-ben minden réteg közvetlen összeköttetésben áll az összes megelőző réteg jellemzőterképével, a hálózat képes volt az alacsony szintű vizuális jegyeket (mint az élek és finom lokális textúrák) közvetlenül kombinálni a mélyebb rétegek magas szintű szemantikus információival. Ez a folyamatos feature-újjrahasznosítás megakadályozta, hogy a hálózat kizárólag a gyermekbetegekre jellemző, sűrűbb központi árnyékokra ha-

gyatkozzon a döntés során. Ennek köszönhetően a DenseNet121 sokkal finomabb és pontosabb osztályhatárokat tudott meghúzni a normális szöveti denzitás és a tényleges kóros infiltrátumok között.


4.1.3. EfficientNetB0 eredményei

A strukturálisan optimalizált EfficientNetB0 architektúra validálása szintén a 624 mintából álló gyári tesztalmazon valósult meg. Az ImageNet-en előtanított hálózat az alapértelmezett paraméterek és a 0,5-ös döntési küszöb alkalmazása mellett 87,34%-os globális pontosságot (accuracy) produkált. A modell részletes, osztályszintű teljesítménymutatóit a 4.3. táblázat tartalmazza.

4.3. táblázat. A EfficientNetB0 modell részletes osztályozási metrikái

Osztály	Precision	Recall	F1-score	Support
NORMAL	0,8855	0,7607	0,8184	234
PNEUMONIA	0,8676	0,9410	0,9028	390
Macro Avg	0,8766	0,8508	0,8606	624
Weighted Avg	0,8743	0,8734	0,8711	624

A metrikai elemzés alapján megállapítható, hogy az EfficientNetB0 stabil köztes pontot képvisel az eddig vizsgált architektúrák között. A tüdőgyulladással érintett felvételeket megbízhatóan, 94,10%-os recall értékkel ismerte fel, amellyel minimálisan ugyan elmarad a ResNet50 mögött, de hozza a klinikai szűréshez szükséges magas biztonsági szintet. A legfőbb előrelépés a ResNet50-hez képest a *NORMAL* osztály recall mutatójában mutatkozik meg, amely 72,65%-ról 76,07%-ra növekedett, jelezve, hogy az architektúra pontosabban képes elkülöníteni az egészséges tüdőszövetet. A modell osztályozási eloszlását a 4.3a. ábrán látható konfúziós mátrix mutatja be.



(a) Konfúziós mátrix

(b) ROC-AUC görbe

4.3. ábra. Az EfficientNetB0 modell teljesítményének részletes kiértékelése a tesztalmazon

A konfúziós mátrix számszerűsített adatai alapján a hálózat a 390 tüdőgyulladásos képből 367 esetben hozott helyes döntést (True Positive), és 23 mintát tévesztett el (False Negative). Ezzel párhuzamosan a 234 egészséges kontrollfelvételtől 178 darabot sorolt be megfelelően (True Negative), míg a fals pozitív tévesztések száma 56 lett (False Positive).

Módszertani szempontból kiemelendő, hogy az EfficientNetB0 ezt az eredményt radikálisan alacsonyabb erőforrás-igény mellett érte el, mint a korábbi modellek. Az úgynevezett compound scaling technológia – amely egy fix együttható mentén egyszerre skálazza a hálózat mélységét, szélességét és a bemeneti képek felbontását – rendkívül koncentrált jellemzőkinyerést tesz lehetővé. Bár a DenseNet121 abszolút pontosságát (89,74%) nem sikerült elérnie, az EfficientNetB0 csupán $\approx 5,3$ millió paramétert mozgat, ami a DenseNet121 méretének nagyjából kétharmada, a ResNet50-nek pedig alig egyötöde. A modell struktúrája hatékonyan védte ki a túlilleszkedést (overfitting) a korlátozott méretű tanítóhalmazon, ami a stabil és kiegyensúlyozott macro F1-score (0,8606) értékben is manifesztálódik.

4.1.4. MobileNetV2 eredményei


Az erőforrás-korlátozott és mobil környezetre optimalizált MobileNetV2 architektúra értékelése a 624 mintából álló gyári teszthalmazon rendkívül figyelemre méltó eredményeket hozott. Az ImageNet súlyokkal inicializált hálózat az alapértelmezett beállítások mellett 90,38%-os globális pontosságot (accuracy) ért el, amellyel az alapértelmezett döntési küszöbös transzfer tanulási fázisban a legmagasabb pozíciót szerezte meg az előtanított modellek között. A hálózat részletes osztályszintű mutatóit a 4.4. táblázat foglalja össze.

4.4. táblázat. A MobileNetV2 modell részletes osztályozási metrikái

Osztály	Precision	Recall	F1-score	Support
NORMAL	0,8566	0,8932	0,8745	234
PNEUMONIA	0,9342	0,9103	0,9221	390
Macro Avg	0,8954	0,9017	0,8983	624
Weighted Avg	0,9051	0,9038	0,9042	624

Az adatok részletes elemzése rávilágít arra, hogy a MobileNetV2 nyújtotta a leginkább kiegyensúlyozott és harmonikus teljesítményt az alapkonzfigurációk körében. Nemcsak a tüdőgyulladásos eseteket ismerte fel kiváló, 91,03%-os recall értékkel, hanem a *NORMAL* osztályban is egyedülálló, 89,32%-os recall mutatót produkált. Ez a magas szintű szimmetria biztosítja, hogy a modell minimális fals pozitív és fals negatív hibával dolgozzon, ami elengedhetetlen a klinikai diagnosztikai megbízhatóságához. A hálózat pontos döntési mechanizmusát a 4.4a. ábrán látható konfúziós mátrix szemlélteti.

A konfúziós mátrix számszerű eloszlása igazolja a hálózat kimagasló szelektivitását: a 390 tüdőgyulladásos képből 355 esetet diagnosztizált helyesen (True Positive), és



4.4. ábra. A MobileNetV2 modell teljesítményének részletes kiértékelése a teszhalmazon

csupán 35 mintát tévesztett el (False Negative). Az igazi áttörést azonban az egészséges kontrollcsoport kezelése jelentette, ahol a 234 normál felvételtől 209 darabot sorolt be hibátlanul (True Negative), és a fals pozitív riasztások számát mindössze 25-re szorította vissza (False Positive).

Mérnöki és informatikai szempontból ez a teljesítmény rendkívüli eredménynek minősül az architektúra méretének tükrében. A MobileNetV2 a mélységi elválasztható konvolúciók (depthwise separable convolutions) és az invertált reziduális blokkok (inverted residual blocks) alkalmazásával a paraméterszámát mindössze $\approx 3,4$ millióra redukálja. Ennek ellenére képes volt felülmúlni a nála nagyságrendekkel komplexebb és több memóriát igénylő ResNet50 és DenseNet121 hálózatokat ezen a specifikus feladaton. A magas macro F1-score (0,8983) egyértelműen bizonyítja, hogy az architektúra belső reprezentációs tere kiválóan adaptálódott a szürkeárnyaltos tüdőrontgenek finom texturális eltéréseihez, igazolva a peremhálózati (edge AI) és telemedicinás alkalmazásokban rejlő létjogosultságát.

4.1.5. VGG16 ($t = 0,5$) eredményei


Az összehasonlítás utolsó tagjaként a klasszikus, mély konvolúciós VGG16 architektúrát vettem alá a 624 mintás gyári teszhalmazon történő kiértékelésnek. A hálózat a standard, kétfázisú transzfer tanulást követően, az alapértelmezett 0,5-ös döntési küszöb mellett 88,62%-os globális pontosságot (accuracy) produkált. A modell részletes, osztályokra bontott teljesítménymutatóit a 4.5. táblázat reprezentálja.

A kapott mérési eredmények egy rendkívül aszimmetrikus, ugyanakkor komoly potenciállal rendelkező modellt körvonalaznak. A VGG16 elért egy klinikailag megkérdőjelezhetetlen, 98,72%-os recall értéket a tüdőgyulladásos eseteknél, ami azt jelenti, hogy a beteg mintáknak csupán egy elhanyagolható töredékét mulasztotta el. Ezzel

4.5. táblázat. A VGG16 ($t = 0,5$) modell részletes osztályozási metrikái

Osztály	Precision	Recall	F1-score	Support
NORMAL	0,9600	0,7179	0,8215	234
PNEUMONIA	0,8518	0,9872	0,9145	390
Macro Avg	0,9059	0,8526	0,8680	624
Weighted Avg	0,8924	0,8862	0,8796	624

párhuzamosan azonban a *NORMAL* osztály recall mutatója kritikus szintre, 71,79%-ra süllyedt. Ez a torzítás az egészséges páciensek jelentős hányadának téves diagnosztizálását vonta maga után. A hálózat belső osztályelrendezését és a hibák megoszlását a 4.5a. ábrán látható konfúziós mátrix szemlélteti.



4.5. ábra. A VGG16 ($t = 0,5$) modell teljesítményének részletes kiértékelése a teszt-halmazon

A konfúziós mátrix adatai pontosan megmutatják ezt az extrém eltolódást: a 390 tüdőgyulladásos felvételtől a modell lenyűgöző pontossággal, 385 esetben hozott helyes döntést (True Positive), és mindössze 5 beteget hagyott figyelmen kívül (False Negative). Ezzel ellentétben a 234 egészséges képből 66 darabot tévesen a patológias osztályba rendelt (False Positive), és csak 168 esetben igazolta a normál állapotot (True Negative).

Annak ellenére, hogy ez a gyakorlati kiegyensúlyozatlanság korlátozza az azonnali klinikai alkalmazhatóságot, az architektúra belső matematikai képességei kiemelkedőek. Ezt bizonyítja a rendkívül magas, 0,9726-os ROC-AUC érték is. A magas AUC mutató arra utal, hogy a VGG16 geometriai értelemben kiválóan képes szeparálni a két osztály valószínűségi eloszlását, a hiba pusztán abból adódik, hogy az alapértelmezett 0,5-ös osztályozási küszöbvonal rossz helyen lett meghúzva. A hálózat a tanítás során a többségi osztály felé tolódott el, de a tiszta szeparációs ereje miatt egyértelműen ezt az architektúrát választottam a későbbi optimalizációs lépések és a finomhangolási kísérletek abszolút alapjául.

4.2. A VGG16 architektúra iteratív optimalizációja és a pipeline evolúciója

Mivel az alapmodellek összehasonlítása során a VGG16 architektúra mutatta a leg-erősebb osztályszeparációs képességet (0,9726 ROC–AUC), ezt a modellt választottam ki a projekt gerincét képező iteratív fejlesztési folyamat alapjául. A következőkben bemutatott kísérleti fázisok egy mérnöki evolúciós láncolatot alkotnak, ahol minden egyes lépés egy korábban azonosított limitáció vagy hiba szisztematikus felszámolására irányul.

4.2.1. Fázis 2: Szisztematikus döntési küszöb optimalizáció

Az alapértelmezett 0,5-ös küszöbérték alkalmazása mellett a VGG16 extrém módon eltolódott a pneumonia osztály irányába, ami a klinikai gyakorlatban elfogadhatatlanul magas fals pozitív arányt eredményezett (71,79% NORMAL recall). Ennek a döntési aszimmetriának a kezelésére a hálózat súlyainak változatlanul hagyása mellett a kimeneti valószínűségeket kiértékelő döntési mechanizmust szisztematikus optimalizálásnak vettem alá.


A kísérlet során a validációs halmazon végzett automatizált küszöbkeresés során az F1-score maximalizálását tűztem ki célul, szem előtt tartva a szenzitivitás és a specificitás közötti klinikailag biztonságos egyensúlyt. Az így meghatározott optimális küszöbérték mellett elért részletes teszteredményeket a 4.6. táblázat foglalja össze.

4.6. táblázat. A VGG16 (optimalizált threshold) modell részletes osztályozási metrikái

Osztály	Precision	Recall	F1-score	Support
NORMAL	0,9534	0,7863	0,8618	234
PNEUMONIA	0,8822	0,9769	0,9271	390
Macro Avg	0,9178	0,8816	0,8945	624
Weighted Avg	0,9089	0,9054	0,9026	624

A mérési adatok egyértelműen igazolják a döntési stratégia megváltoztatásának hatékonyságát. A modell globális pontossága (accuracy) 88,62%-ról 90,54%-ra növekedett, miközben a modell belső eloszlásának elméleti minőségét jelző ROC–AUC mutató stabilan magas szinten, 0,9748-as értéken maradt.

A legfontosabb kvalitatív előrelépés a *NORMAL* osztály recall értékében mutatkozik meg, amely a kiinduló fázishoz képest azonnal 71,79%-ról 78,63%-ra ugrott. Ez azt jelenti, hogy az egészséges képek helyes felismerése drasztikusan megemelkedett, ezáltal a fals pozitív riasztások száma érdemben visszaesett. Ezzel egy időben a tüdőgyulladásos esetek detektálási aránya (PNEUMONIA recall) továbbra is a klinikailag biztonságos és magas, 97,69%-os tartományban maradt, megőrizve a szűrés biztonságát. A modell optimalizált döntési megoszlását a 4.6a. ábrán látható konfúziós mátrix szemlélteti.



4.6. ábra. A VGG16 (optimalizált threshold) modell teljesítményének kiértékelése

A konfúziós mátrix számszerű ellenőrzése pontosan megmutatja a változás dinamikáját. A 234 egészséges kontrollfelvételtől a modell immár 184 esetben hozott helyes döntést (True Negative), a fals pozitív tévesztéseket pedig sikerült 66-ról 50-re redukálni. A 390 tüdőgyulladásos mintából 381 esetet azonosított sikeresen (True Positive), és mindössze 9 beteg röntgenfelvételt vettette el (False Negative).

Ez a kísérlet kulcsfontosságú elméleti tanulsággal szolgált. Bebizonyította, hogy egy neurális hálózat klinikai alkalmazhatóságát nem kizárólag a konvolúciós rétegek mélysége határozza meg, hanem a kimeneti valószínűségeket kiértékelő döntési stratégia helyes megválasztása is. A matematikai optimum eltolásával anélkül sikerült egy sokkal kiegyensúlyozottabb diagnosztikai rendszert kapni, hogy a hálózat súlyait újra kellett volna tanítani.

4.2.2. Fázis 3: LAB szintér alapú CLAHE kontraszt-egyenlítést alkalmazó VGG16 pipeline

Bár a döntési küszöb optimalizálása szoftveres oldalon sokat javított a metrikákon, a modell webalkalmazáson keresztül történő, valós idejű tesztelése során egy kritikus gyakorlati problémára derült fény. A felhasználók által feltöltött, külső forrásból származó (idegen) röntgenfelvételek esetében a hálózat predikciós képessége jelentősen romlott.

A háttérben meghúzódó ok a gépi tanulásban jól ismert tartomány-eltolódás (domain shift) jelensége: a különböző kórházakban, eltérő röntgengépekkel és expozíciós beállításokkal készült felvételek globális kontrasztja és fényereje radikálisan eltérhet a tanítóhalmaz statisztikai tulajdonságaitól. Ennek a vizuális varianciának a felszámolására a VGG16 architektúra elé beépítettem a CLAHE (*Contrast Limited Adaptive Histogram Equalization*) adaptív kontraszt-kiegyenlítési eljárást.

A CLAHE célja, hogy a bemeneti képek lokális hisztogramjait régióként simítsa


és kiegyenlítse, miközben a zaj felerősödését egy szigorú határértékkel korlátozza. Ez az előfeldolgozás a képeket olyan standardizált kontraszt-tartományba hozza, amelyet a hálózat már biztonsággal képes értelmezni. A CLAHE előfeldolgozással kiegészített, optimalizált küszöbű VGG16 modell gyári tesztalmazon mért eredményeit a 4.7. táblázat foglalja össze.

4.7. táblázat. A VGG16 + CLAHE modell részletes osztályozási metrikái

Osztály	Precision	Recall	F1-score	Support
NORMAL	0,9507	0,8248	0,8833	234
PNEUMONIA	0,9026	0,9744	0,9371	390
Macro Avg	0,9267	0,8996	0,9102	624
Weighted Avg	0,9207	0,9183	0,9169	624

A mérési eredmények azt mutatják, hogy a matematikai hisztogram-standardizálás nemcsak a külső (webalkalmazásos) tesztek során növelte meg a rendszer robusztusságát, hanem a gyári tesztalmazon is közvetlenül mérhető minőségi javulást eredményezett. A globális pontosság 90,54%-ról 91,83%-ra emelkedett, a ROC-AUC érték pedig elérte a 0,9756-ot.

A legfontosabb előrelépés ismét a *NORMAL* osztályban realizálódott, ahol a recall érték a korábbi 78,63%-ról tovább javulva elérte a 82,48%-ot. Ez igazolja, hogy a kontraszt kiegyenlítésével a hálózat sokkal magabiztosabban tudta azonosítani a tüdő sötétebb, egészséges területeit. Eközben a tüdőgyulladásos esetek felidézése (97,44% PNEUMONIA recall) megőrizte magas klinikai stabilitását. A modell döntési mátrixát a 4.7a. ábrán látható konfúziós mátrix mutatja be.



4.7. ábra. A VGG16 + CLAHE modell teljesítményének részletes kiértékelése

A konfúziós mátrix adatai alapján látható, hogy a 234 egészséges kontrollfelvételtől a modell immár 193 darabot pontosan diagnosztizált (True Negative), és a fals pozitív tévesztések száma 41-re csökkent. A 390 tüdőgyulladásos képből 380 esetet talált meg sikeresen (True Positive), és mindössze 10 darabot vétett el (False Negative).

Összességében a kísérlet igazolta, hogy a determinisztikus kép-standardizálás alapvető fontosságú a domain shift hatásainak csökkentésében. Bár a külső, idegen képeken tapasztalt bizonytalanságot ez a lépés önmagában még nem számolta fel teljesen, a CLAHE integrálása a feldolgozási láncba (pipeline) elengedhetetlen építőelemnek bizonyult a későbbi, összetettebb geometriai kísérletek megalapozásához.

4.2.3. Fázis 4: Mesterséges intelligencia alapú tüdőszegmentációt alkalmazó kétszintű pipeline

A domain shift jelenség radikális és strukturális felszámolására a kísérletsorozat ezen pontján egy komplexebb, kétszintű feldolgozási láncot (*two-stage pipeline*) terveztem. Az elméleti megközelítés alapját az a felismerés adta, hogy a mellkasröntgeneken a tüdő anatómiai struktúráján kívül számos zavaró tényező található – például külső szöveges feliratok, diagnosztikai kábelek, a váll és a nyak csontszerkezete, valamint egyedi műtermékek. Ha a hálózatot rákényszerítjük, hogy kizárólag a tényleges tüdőterületet (Region of Interest – ROI) lássa, a háttér statisztikai varianciája és az idegen képekből származó tartomány-eltolódás nem képes megzavarni a döntéshozatalt.


A ROI izolálására egy nyilvánosan elérhető, előtanított deep learning alapú U-Net szegmentációs modellt [14] (`unet_lung_seg.hdf5`) integráltam a pipeline első lépéseként. A kidolgozott architektúra az alábbi szekvenciális lépéseken ment keresztül: a bemeneti képből az U-Net legenerálta a bináris tüdőmaszkot, ezt követte a maszk körvonalára illesztett vágás (*masked crop*), a kivágott tüdőterület LAB-alapú CLAHE kontraszt-standardizálása, majd legvégül a VGG16 hálózattal történő osztályozás. A komplex pipeline gyári teszthalmazon mért eredményeit a 4.8. táblázat összegzi.

4.8. táblázat. A VGG16 + U-Net + CLAHE modell részletes osztályozási metrikái

Osztály	Precision	Recall	F1-score	Support
NORMAL	0,9058	0,8632	0,8840	234
PNEUMONIA	0,9202	0,9462	0,9330	390
Macro Avg	0,9130	0,9047	0,9085	624
Weighted Avg	0,9148	0,9151	0,9146	624

A mérési adatok elemzése komoly elméleti és gyakorlati tanulsággal szolgált. A globális pontosság (91,51%) és a ROC-AUC érték (0,9682) nemhogy nem javult, de minimálisan el is maradt a tisztán CLAHE-alapú előfeldolgozástól (91,83%). Bár a *NORMAL* osztály recall értéke tovább emelkedett 86,32%-ra, a *PNEUMONIA* recall klinikailag veszélyes módon visszaesett 94,62%-ra. A modell belső döntési megoszlását a 4.8a. ábrán látható konfúziós mátrix szemlélteti.

A konfúziós mátrix alapján látható, hogy az egészséges osztályban a helyes predikciók száma 202-re nőtt (True Negative), a fals pozitív tévesztés pedig 32-re csökkent. Ugyanakkor a tüdőgyulladásos mintákból a modell a korábbi 5-10 tévesztés helyett immár 21 esetet mulasztott el (False Negative), ami diagnosztikai szempontból kritikus



4.8. ábra. A VGG16 + U-Net + CLAHE modell teljesítményének részletes kiértékelése

visszalépés.

A megközelítés korlátainak feltárása során bebizonyosodott, hogy maga a szegmentációs U-Net modell is érzékeny volt a domain shift jelenségére. Mivel az U-Net architektúrát felnőtt páciensek mellkasfelvételein tanították, képtelen volt stabilan adaptálódni a Paul Mooney-féle adatkészlet sajátosságaihoz, amely túlnyomórészt gyermekgyógyászati (pediátriai) mintákat tartalmaz. A gyermekek tüdőstruktúrája, anatómiai formája és arányai radikálisan eltérnek a felnőttekétől.

Ennek következtében az U-Net számos képen torz, hiányos vagy teljesen téves maszkokat generált – például lefejezte a tüdőcsúcsokat vagy elvágta a gyulladásos infiltrátumok által elhomályosított alsó lebenyeket. A pipeline második lépcsőjében lévő VGG16 így helyenként csonka képeken vagy anatómiailag irreleváns részeken kényszerült tanulni és predikciót hozni. Ez a fázis rávilágított arra, hogy egy szofisztikált gépi tanulási előfeldolgozó lánc beépítése kontraproduktív válnak, ha a láncolat első eleme maga is sérülékeny a domain shift-tel szemben.


4.2.4. Fázis 5: Determinisztikus aszimmetrikus center crop és CLAHE előfeldolgozási pipeline

Az U-Net alapú szegmentációs kísérletből levont tanulságok rávilágítottak arra, hogy a gépi tanulási komponenseket tartalmazó előfeldolgozási láncok maguk is sérülékenyek az adatok statisztikai eltolódásával szemben. Ezt a limitációt felszámolandó, a kísérletsorozat ezen fázisában egy egyszerűbb, de strukturálisan lényegesen robusztusabb megközelítést alkalmaztam. Egy olyan determinisztikus, tisztán matematikai alapú előfeldolgozási stratégiát fejlesztettem ki, amely nem tartalmaz tanuló komponenst, ezáltal teljesen immúnis a domain shift jelenségére.

A módszer egy specifikusan hangolt *aszimmetrikus center crop* eljárásra épül. A


vágási arányokat a mellkasröntgenek tipikus anatómiai elrendezéséhez igazítottam egy átfogó vizuális ellenőrzési (*sanity check*) folyamat segítségével. Mivel a felvételek felső részén elhelyezkedő nyak- és vállstruktúrák, valamint a kulcscsontok dús szövetei semmilyen releváns információt nem hordoznak a tüdőgyulladás szempontjából (viszont gyakran tartalmaznak zavaró műtermékeket vagy külső feliratokat), felülről jóval nagyobb margó eltávolítását határoztam meg. A véglegesített, fix vágási paraméterek a következők szerint alakultak: felülről 15%, alulról 5%, balról 5%, valamint jobbról 5% került levágásra.

A vágást követően a megmaradt releváns tüdőrégiót a korábban bevált LAB-alapú CLAHE eljárással standardizáltam kontraszt szempontjából, majd átadtam az osztályozást végző VGG16 hálózathoz. Az előfeldolgozási lánc sematikus blokkdiagramját a 4.9. ábra foglalja össze.



4.9. ábra. A determinisztikus előfeldolgozási pipeline blokkdiagramja

Az előfeldolgozás vizuális működését és az aszimmetrikus vágás pontosságát a 4.10. ábrán látható minőségellenőrzési (*sanity check*) mintakép szemlélteti.



4.10. ábra. Az aszimmetrikus center crop és CLAHE előfeldolgozás vizuális ellenőrzése (*sanity check*)


A determinisztikus pipeline gyári tesztalmazon (Kaggle) mért eredményeit a 4.9. táblázat foglalja össze.

4.9. táblázat. A VGG16 + aszimmetrikus crop + CLAHE modell részletes osztályozási metrikái

Osztály	Precision	Recall	F1-score	Support
NORMAL	0,9375	0,8333	0,8824	234
PNEUMONIA	0,9062	0,9667	0,9355	390
Macro Avg	0,9219	0,9000	0,9089	624
Weighted Avg	0,9180	0,9167	0,9156	624

A metrikák elemzése megmutatja, hogy ez a letisztult, szabályalapú architektúra a gyári tesztalmazon a komplex U-Net-es verziót felülmúlva, a tisztán CLAHE-alapú változattal szinte megegyező, magas minőséget produkált. A globális pontosság stabil 91,67% lett, miközben a ROC-AUC érték 0,9742-es szinten stabilizálódott.

A modell kiváló egyensúlyt ért el az osztályok között: a *NORMAL* recall értéke 83,33%-ra emelkedett, míg a *PNEUMONIA* recall szilárdan a biztonságos 96,67%-os értéken maradt. A hálózat osztályozási eloszlását a 4.11a. ábrán látható konfúziós mátrix szemlélteti.



4.11. ábra. A VGG16 + aszimmetrikus crop + CLAHE modell teljesítményének kiértékelése

A konfúziós mátrix számszerűsített adatai alapján a hálózat a 234 egészséges kontrollképből 195 darabot ismert fel helyesen (True Negative), és a téves riasztások számát 39-re redukálta. A 390 tüdőgyulladásos felvételtől 377 esetben hozott helyes döntést (True Positive), és mindössze 13 mintát vétett el (False Negative).

Szoftverarchitektúra-tervezési szempontból ez a fázis jelenti az adatelőkészítő pipeline végleges, optimális verzióját a gyári adatkészlet környezetében. Bár a pusztán tesztmetrikák alapján a javulás minimálisnak tűnhet a tisztán CLAHE-alapú változathoz képest, a rendszer valódi előnye az adatfüggetlen megbízhatóságban rejlik. Mivel a preprocessing lépés nem támaszkodik külső statisztikai eloszlásokra vagy más adathal-

mazon tanult súlyokra, ez a konfiguráció lényegesen magasabb stabilitást és robusztuságot garantál a webalkalmazáson keresztül érkező, teljesen ismeretlen, külső klinikai forrásból származó képek tesztelése során is.

4.2.5. Fázis 6: A véglegesített pipeline adaptációja a COVID-19 Radiography adatkészletre

A kutatás következő fázisában a cél a kereszt-adatkészletes generalizációs képesség (*cross-dataset generalization*) vizsgálatának előkészítése volt. Ehhez szükségessé vált egy olyan második, teljesen független forrásból származó modell felépítése, amely az előző fázisban optimalizált, azonos előfeldolgozási architektúrát (aszimmetrikus center crop és LAB-alapú CLAHE) és döntési stratégiát alkalmazza, de egy radikálisan eltérő statisztikai tulajdonságokkal rendelkező adatbázison tanul. Erre a célra a Chowdhury et al. által publikált *COVID-19 Radiography Database*-t választottam.


Ez az adatbázis több kritikus szempontból is eltér a Paul Mooney-féle gyári Kaggle adatkészlettől. Míg a korábbi adatok túlnyomórészt gyermekgyógyászati mintákból álltak, addig a COVID-19 adatkészlet felnőtt páciensek felvételeit tartalmazza, a képminősége lényegesen homogénebb, az osztályok eloszlása pedig komoly aszimmetriát mutat (10 192 *NORMAL* és 1345 *Viral Pneumonia* minta). Mivel ez az adatbázis nem rendelkezett gyárilag elkülönített felosztással, a transzfer tanulás módszertanának megfelelően magam végeztem el a minták szétválasztását 80% tanító, 10% validációs és 10% tesztelési arányban. A torzítások elkerülése érdekében szigorú stratifikált mintavételt (*stratified split*) alkalmaztam, amely garantálta az osztályarányok hiánytalan megőrzését mindhárom részhalmazban. A kutatás fókuszának megtartása érdekében a COVID és a Lung Opacity osztályokat teljesen kizártam a kísérletből, így kizárólag a két osztályos (*NORMAL* vs. *Viral Pneumonia*) osztályozásra koncentráltam. A modell saját teszthalmazán mért eredményeit a 4.10. táblázat reprezentálja.

4.10. táblázat. A VGG16 + crop + CLAHE (COVID-19 adatkészlet) modell részletes osztályozási metrikái

Osztály	Precision	Recall	F1-score	Support
NORMAL	0,9902	0,9941	0,9922	1019
PNEUMONIA	0,9545	0,9254	0,9394	134
Macro Avg	0,9724	0,9598	0,9658	1153
Weighted Avg	0,9861	0,9861	0,9860	1153

A mérési adatok elemzése kimagasló, szinte ideális teljesítményt mutat. A modell globális pontossága elérte a 98,61%-ot, míg a ROC-AUC mutató 0,9987-es értéke matematikai értelemben véve is gyakorlatilag tökéletes osztályszeparációs képességre utal a hálózat látens reprezentációs terében.

A részletes osztályszintű bontás alapján látható, hogy a masszív többségben lévő *NORMAL* kontrollcsoportot a hálózat szinte hiba nélkül, 99,41%-os recall mutatóval kezelte. Ezzel párhuzamosan a kisebbségi patológiás minták detektálása (92,54% PNEUMONIA recall) is magasan a klinikai elvárásokon belül maradt. A hálózat belső eloszlását a 4.12a. ábrán látható konfúziós mátrix szemlélteti.



4.12. ábra. A VGG16 + crop + CLAHE (COVID adatkészlet) modell teljesítményének kiértékelése

A konfúziós mátrix számszerűsített adatai megerősítik a modell magabiztosságát: az 1019 egészséges tesztképből mindössze 6 darabot tévesztett el (False Positive), míg a 134 tüdőgyulladásos röntgenfelvételtől 124 esetet sikeresen izolált (True Positive), és csupán 10 beteget mulasztott el (False Negative).

Módszertani szempontból fontos rávilágítani, hogy ezek a rendkívül magas metrikák jelentős részben a COVID-19 Radiography Database magasabb technikai színvonalának, a felvételek homogénebb digitális minőségének, valamint a felnőtt anatómia jóval kisebb strukturális varianciájának köszönhetők. Önmagában ez a kiemelkedő saját teszthalmas teljesítmény azonban még nem bizonyítja a modell valódi robusztusságát. A következő fejezetben bemutatott kereszt-adatkészletes (*cross-dataset*) validáció fogja érdemben feltárni, hogy ez a hálózat mennyire képes megőrizni a predikciós erejét, ha egy teljesen idegen, más demográfiai és technikai forrásból származó környezetből kap bemeneti felvételeket.

4.3. Kereszt-adatkészlet (Cross-Dataset) validáció és a Domain Shift számszerűsítése

A gépi tanulás alapú orvosi diagnosztikában az egyik legnagyobb kihívást a modellek általánosíthatósága jelenti. Annak érdekében, hogy számszerűen és megkérdőjelezhetetlenül bizonyítsam a tartomány-eltolódás (domain shift) jelenlétét és hatásait, a ko-

rábbi fázisokban felépített két azonos architektúrájú (VGG16 + aszimmetrikus crop + CLAHE), de eltérő forrásból származó hálózatot keresztbe teszteltem egymás független tesztthalmazain.

A kísérlet során a Paul Mooney-féle gyári Kaggle adatkészleten tanított hálózatot ráengedtem a COVID-19 Radiography Database tesztaszegmensére, majd a folyamatot megfordítva, a COVID-19 adatokon nevelt modellt validáltam a Kaggle tesztmintáin. A négy kiértékelt kombináció eredményeit a 4.11. táblázat foglalja össze.

4.11. táblázat. Kereszt-adatkészlet (Cross-Dataset) kiértékelési mátrix

Modell forrása	Tesztkörnyezet	Pontosság	ROC-AUC	NORMAL Recall	PNEUMONIA Recall
VGG16 (Kaggle)	Kaggle (saját)	91,67%	0,9742	83,33%	96,67%
VGG16 (Kaggle)	COVID Rad. (idegen)	56,76%	0,8360	51,76%	94,78%
VGG16 (COVID Rad.)	COVID Rad. (saját)	98,61%	0,9987	99,41%	92,54%
VGG16 (COVID Rad.)	Kaggle (idegen)	84,29%	0,9685	58,97%	99,49%

A mérési adatok egyértelműen igazolják, hogy a saját tesztthalmazon elért kiemelkedő eredmények önmagukban nem garantálják a modell klinikai robusztusságát egy idegen környezetben. Mindkét hálózat esetében jól látható teljesítménycsökkenés következett be az ismeretlen forrásból származó képek hatására, azonban a két modell aszimmetrikus módon reagált a változásra.


A gyermektüdő-röntgeneken nevelt Kaggle-modell teljesítménye az idegen, felnőtt pácienseket tartalmazó környezetben drasztikusan összeomlott: a globális pontossága 91,67%-ról 56,76%-ra esett vissza. A modell predikciós eloszlása kritikus módon eltolódott a patológia irányába; szinte minden bemenetet tüdőgyulladásosnak minősített (94,78% PNEUMONIA recall), ami miatt az egészséges kontrollfelvételek csaknem felét tévesen pozitívnak ítélte meg (51,76% NORMAL recall).

Ezzel szemben a felnőtt mintákon tanított COVID Radiography modell lényegesen robusztusabb általánosítási képességről tett tanúbizonyságot. Bár a pontossága 98,61%-ról 84,29%-ra csökkent a gyermektüdő-képeken, a látens tér szeparálhatóságát mutató ROC-AUC értéke idegen halmazon is rendkívül magas, 0,9685-ös szinten maradt. Ennek a modellnek a legfőbb gyengesége szintén a *NORMAL* osztály felidézésében mutatkozott meg (58,97% recall). Ez a torzítás közvetlen következménye a COVID-19 adatkészlet masszív osztály-kiegyensúlyozatlanságának (10 192 normál kép állt szemben mindössze 1345 vírusos tüdőgyulladásos képpel), amely miatt a hálózat alapértelmezetten óvatosabb döntési stratégiát alakított ki a kisebbségi osztállyal szemben.

Klinikai és diagnosztikai szempontból kiemelendő, rendkívül fontos megfigyelés, hogy mindkét modell esetében a *NORMAL* osztály precizitása (Precision) az idegen tesztthalmazokon is kimagasló, 98% feletti értékű maradt (a Kaggle modellnél 98,69%, a COVID modellnél 98,57%). Ez a gyakorlatban azt jelenti, hogy amennyiben a rendszer egy képre azt a predikciót adja, hogy egészséges (*NORMAL*), az az esetek túlnyomó, szinte abszolút többségében a valóságban is az. A modellek elsődleges hibaforrását te-

hát nem az elszalasztott betegek jelentik, hanem a tévesen generált pozitív (fals pozitív) riasztások magas száma.

A két modell kereszttesztelése során tapasztalt aszimmetrikus teljesítménycsökkenést, valamint a saját és idegen környezet közötti metrikai eltéréseket a 4.13. ábrán látható összevont oszlopdiagram szemlélteti szemléletesen.



4.13. ábra. A VGG16 modellek kereszt-adatkészletes (Cross-Dataset) teljesítményének összehasonlító diagramja

Mérnöki szempontból a kereszt-adatkészletes ROC–AUC értékek (0,8360 és 0,9685) arra világítanak rá, hogy a konvolúciós rétegek által kinyert geometriai jellemzők osztályszeparációs képessége nem veszett el porrá az idegen képeken sem, csupán a döntési tartományok határai tolódtak el az adathalmazok statisztikai különbözősége miatt. Ez a felismerés egyrészt előrevetíti, hogy a döntési küszöbök egyedi, környezetfüggő utóhangolásával a modellek idegen adaton nyújtott teljesítménye szoftveresen is javítható lenne, másrészt kijelöli az egyetlen valódi, rendszerszintű megoldást: egy olyan kombinált adatkészlet létrehozását, amely egyesíti mindkét forrás demográfiai és technikai diverzitását.

4.4. Transzfer tanulás kombinált, diverzifikált adatkészleten

4.4.1. VGG16 + crop + CLAHE eredményei kombinált adatkészleten

A kereszt-adatkészletes validáció során nyert kritikus tanulságok egyértelművé tették, hogy sem a bonyolult szegmentációs eljárások, sem a lokális képjavító algoritmusok nem képesek teljes körűen felszámolni a tartomány-eltolódás (domain shift) és az osztálykiegyensúlyozatlanság együttes hatásait, ha a tanítás egyetlen forrásra korlátozódik. A radikális rendszerszintű megoldást egy olyan összevont, kombinált adatkészlet (*combined dataset*) létrehozása jelentette, amely egyesíti a Paul Mooney-féle gyermektüdő-


röntgeneket és a COVID-19 Radiography Database felnőtt pácienseinek felvételeit, ezáltal biztosítva a szükséges demográfiai és technikai diverzitást.

Az adatok integrációja során egy egyedi előkészítő szkript segítségével kiegyensúlyozott alulmintavételezést (*balanced undersampling*) alkalmaztam: a domináns *NORMAL* osztály méretét a kisebbségi *PNEUMONIA* osztály szintjére csökkentettem, eliminálva a korábbi fázisokban tapasztalt döntési torzításokat. Az így létrejött adatkészlet összesen 11 236 képet tartalmazott, amelyet stratifikált módon 80% tanító (4494 *NORMAL* + 4494 *PNEUMONIA*), 10% validációs és 10% tesztelési arányban osztottam fel. A pipeline architektúrája megegyezett a korábban optimalizált változattal (VGG16 + aszimmetrikus center crop + LAB-alapú CLAHE), a tanítás pedig kétfázisú transzfer tanulással valósult meg. A modell összevont tesztalmazon produkált eredményeit a 4.12. táblázat foglalja össze.

4.12. táblázat. A VGG16 + crop + CLAHE (Kombinált adatkészlet) modell részletes osztályozási metrikái

Osztály	Precision	Recall	F1-score	Support
NORMAL	0,9946	0,9875	0,9910	562
PNEUMONIA	0,9821	0,9947	0,9884	562
Macro Avg	0,9884	0,9911	0,9897	1124
Weighted Avg	0,9884	0,9911	0,9897	1124

A mérési adatok elemzése alapján megállapítható, hogy ez a konfiguráció hozta meg a kutatási projekt abszolút csúcsteljesítményét. A hálózat 99,11%-os globális pontosságot (accuracy) és 0,9984-es ROC–AUC értéket ért el. Ez az első olyan kísérleti fázis, ahol a szigorú és konzisztens adat-előkészítésnek köszönhetően mindkét osztály recall mutatója egyidejűleg és magabiztosan meghaladta a 98%-os (98,75% és 99,47%) klinikai álmohatárt. A modell szinte tökéletes osztályozási eloszlását a 4.14a. ábrán látható konfúziós mátrix szemlélteti.



4.14. ábra. A VGG16 + crop + CLAHE modell konfúziós mátrixa és ROC görbéje a kombinált teszhalmazon

A konfúziós mátrix számszerűsített adatai hűen tükrözik a rendszer kiemelkedő szelektivitását. Az összevont teszhalmazban szereplő 562 egészséges kontrollfelvételtől a modell mindössze 7 darabot tévesztett el (False Positive), míg az 562 tüdőgyulladásos mintából csupán 3 esetben hozott hibás, fals negatív döntést (False Negative).

Mérnöki és adatkutatói szempontból az eredmények egyértelműen igazolják azt a hipotézist, miszerint a deep learning alapú orvosi képfeldolgozásban a domain shift leghatékonyabb ellenszere nem a hálózati architektúrák végtelen bonyolítása vagy a matematikai utófeldolgozás, hanem a tanítóhalmaz reprezentációs diverzifikálása. Azáltal, hogy a hálózat egyszerre találkozott különböző korcsoportok anatómiai sajátosságaival, valamint eltérő gyártmányú röntgenberendezések expozíciós karakterisztikáival, képessé vált olyan univerzális, invariáns vizuális jellemzők kinyerésére, amelyek függetlenek a kép származási helyétől, miközben az undersampling teljesen felszámolta a többségi osztály felé történő strukturális eltolódást.

4.4.2. MobileNetV2 + crop + CLAHE eredményei kombinált adatkészleten


A kísérletsorozat záró fázisában a kutatás fókuszát az architektúráis hatékonyság és a gyakorlati implementálhatóság irányába tereltem. Az előző szakaszban bemutatott VGG16 modell bár kiemelkedő pontosságot ért el, a maga közel 138 millió tanítható paraméterével rendkívül számítás- és memóriairányú (compute-intensive), ami komoly gátat szab a valós idejű, vagy erőforrás-korlátozott klinikai és mobil peremhálózati (*edge computing*) környezetben történő futtatásnak. Annak igazolására, hogy a kidolgozott adatelőkészítési pipeline (aszimmetrikus center crop és LAB-alapú CLAHE) univerzálisan robusztus és független a mögöttes osztályozó hálótól, a VGG16-ot lecseréltem a rendkívül hatékony MobileNetV2 architektúrára.

A MobileNetV2 alapvető strukturális előnye, hogy a hagyományos konvolúciós rétegeket mélységében szétválasztható konvolúciókkal (*depthwise separable convolutions*) váltja ki, ami drasztikusan, mindössze megközelítőleg 3,4 millióra csökkenti a paraméterek számát. A transzfer tanulás finomhangolási (*fine-tuning*) fázisában a hálózat utolsó 30 rétegét oldottam fel a specifikus minták megtanulásához. Mivel a MobileNetV2 beépített reziduális blokkjai és invertált strukturális kötése miatt önmagában is egy erősen regularizált hálózat, az osztályozó fejet (*classifier head*) a VGG16-hoz képest kompaktabbra terveztem: egyetlen 256 neuronos sűrű (Dense) réteget alkalmaztam, mérsékelt, 0,4-es Dropout rátával kiegészítve. A modell összevont tesztalmazon mért eredményeit a 4.13. táblázat foglalja össze.

4.13. táblázat. A MobileNetV2 + crop + CLAHE (Kombinált adatkészlet) modell osztályozási metrikái

Osztály	Precision	Recall	F1-score	Support
NORMAL	0,9784	0,9680	0,9732	562
PNEUMONIA	0,9683	0,9786	0,9734	562
Macro Avg	0,9733	0,9733	0,9733	1124
Weighted Avg	0,9733	0,9733	0,9733	1124

A mérési eredmények elemzése kimagasló technológiai sikert mutat. A pehelysúlyú MobileNetV2 97,33%-os globális pontosságot és 0,9969-es ROC-AUC értéket produkált az összevont adathalmazon. A modell mindkét osztály esetében kiválóan kiegyensúlyozott, a 96%-os határértéket magabiztosan meghaladó felidézési arányt biztosított (96,80% *NORMAL* és 97,86% *PNEUMONIA* recall). Az osztályozás pontos belső eloszlását a 4.15a. ábrán látható konfúziós mátrix szemlélteti.



4.15. ábra. A MobileNetV2 + crop + CLAHE modell konfúziós mátrixa és ROC görbéje a kombinált tesztalmazon

A konfúziós mátrix számszerűsített adatai alapján az 562 egészséges kontrollfelvé-

telből a modell 544 esetben hozott helyes döntést (True Negative), míg az 562 tüdőgyulladásos mintából 550 darabot sikeresen izolált (True Positive). A fals pozitív (18) és a fals negatív (12) tévesztések száma minimális és klinikailag teljesen elfogadható szinten maradt.

A kísérlet legfontosabb mérnöki konklúziója a VGG16 és a MobileNetV2 kombinált verzióinak közvetlen összehasonlításából adódik. Bár a MobileNetV2 globális pontossága 1,78%-kal elmarad a VGG16 abszolút csúcsertékétől, ezt a minimális differenciát a paraméterszám radikális – közel negyvenszeres – csökkenése kíséri. Ez a megállapítás egyértelműen igazolja, hogy a megfelelően diverzifikált adatkészlet és a determinisztikus, robusztus előfeldolgozási pipeline alkalmazásával egy pehelysúlyú, hardveresen rendkívül hatékony architektúra is képes megközelíteni a nehéz, mély modellek klinikai szelektivitását. Ez a modell bizonyítja, hogy a projekt keretében kifejlesztett diagnosztikai rendszer nem csupán elméleti laboratóriumi körülmények között működik, hanem reális alternatívát nyújt az alacsony számítási kapacitású, hordozható orvosi eszközökre történő natív integrációra is.

4.5. Az eredmények globális kiértékelése és konklúzió

A kutatási projekt során elvégzett tizennégy kísérleti fázis és az iteratív pipeline-fejlesztés eredményeit, valamint a megvalósított modellek összesített összehasonlítását a 4.14. táblázat foglalja össze átfogó módon.

4.14. táblázat. A megvalósított modellek és előfeldolgozási konfigurációk összesített összehasonlítása

Modell konfiguráció	Pontosság	ROC–AUC	NORMAL Recall	PNEUMONIA Recall
Baseline CNN	–	–	–	–
ResNet50	86,54%	0,9430	72,65%	94,87%
DenseNet121	89,74%	0,9650	84,19%	93,08%
EfficientNetB0	87,34%	0,9520	76,07%	94,10%
MobileNetV2	90,38%	0,9640	89,32%	91,03%
VGG16 ($t = 0,5$)	88,62%	0,9726	71,79%	98,72%
VGG16 (opt. threshold)	90,54%	0,9748	78,63%	97,69%
VGG16 + CLAHE	91,83%	0,9756	82,48%	97,44%
VGG16 + U-Net + CLAHE	91,51%	0,9682	86,32%	94,62%
VGG16 + crop + CLAHE (Kaggle)	91,67%	0,9742	83,33%	96,67%
VGG16 + crop + CLAHE (COVID)	98,61%	0,9987	99,41%	92,54%
VGG16 + crop + CLAHE (Combined)	99,11%	0,9984	98,75%	99,47%
MobileNetV2 + crop + CLAHE (Combined)	97,33%	0,9969	96,80%	97,86%

A mérési mátrix és a kísérleti tapasztalatok globális elemzése alapján az alábbi főbb tudományos és gyakorlati következtetések vonhatók le:

1. **A transzfer tanulás felsőbbrendűsége:** A mély, előtanított architektúrák mindegyike strukturálisan és érdemben felülmúlta a kezdeti egyedi Baseline CNN modellt. A gyári modellek közül a VGG16 variánsok mutatták a legmagasabb

elméleti osztályszeparációs képességet (ROC–AUC), míg az alap MobileNetV2 a kiemelkedő belső osztályegyensúlyával tűnt ki.

2. **Az előfeldolgozási lánc (pipeline) hatása:** A LAB szintér alapú CLAHE adaptív kontraszt-kiegyenlítés és a determinisztikus aszimmetrikus center crop integrálása nem csupán a numerikus tesztmetrikákat javította szisztematikusan, hanem érdemben növelte a modellek vizuális robusztusságát és stabilitását a valós időben feltöltött, ismeretlen külső képek esetében is.
3. **A komplexitás csapdája (Az U-Net kísérlet tanulsága):** A kutatás rávilágított egy kritikus módszertani axiómára: egy összetettebb, mesterséges intelligenciára épülő előfeldolgozási pipeline (mint az U-Net alapú szegmentáció) önmagában nem garantál jobb eredményt, sőt kontraproduktívvá válhat, ha maga a beépített preprocessing komponens is adatfüggő és érzékeny a domain shift jelenségére (pl. felnőtt mintákon tanult hálózat pediátriai adatokon történő alkalmazása).
4. **A Cross-Dataset validáció realitása:** A kereszt-adatkészletes mérések megerősítették, hogy a zárt, saját teszthalmazon elért magas teljesítmény önmagában nem reprezentálja hűen a modell valós klinikai használhatóságát. Bár a homogénebb, felnőtt COVID Radiography adatbázison tanított modell magasabb alapvető robusztusságot mutatott (0,9685 idegen ROC–AUC), a domain shift negatív hatása (főként a fals pozitív riasztások növekedése) mindkét hálózathoz egyértelműen kimutatható volt.
5. **Az adatok diverzifikálásának áttörő ereje:** A projekt abszolút csúcsteljesítményét a két különálló forrás fúziójával létrehozott, kiegyensúlyozott kombinált adatkészlet hozta meg. A **VGG16 Combined** konfiguráció 99,11%-os globális pontossága és a 98% feletti egyidejű recall értékek bizonyítják, hogy a domain shift és az osztály-kiegyensúlyozatlanság leghatékonyabb kezelése nem a matematikai utófeldolgozás bonyolításában, hanem a tanítóhalmaz demográfiai és technikai diverzifikálásában rejlik.
6. **A peremhálózati (Edge) megvalósíthatóság:** A **MobileNetV2 Combined** modell sikere kiemelkedő gyakorlati jelentőséggel bír. Az a tény, hogy a VGG16 paraméterszámának töredékével ($\approx 3,4$ millió vs. 138 millió) a hálózat mindössze 1,78%-os pontosságbeli eltéréssel, szilárd 97%-os metrikák mellett teljesített, egyértelműen igazolja, hogy az erőforrás-hatékony, modern architektúrák valid alternatívát jelentenek a hordozható, mobil vagy peremhálózati klinikai diagnosztikai rendszerek fejlesztésében.

5. fejezet

A klinikai prototípus webalkalmazás fejlesztése

A kutatási fázisok során elért elméleti eredmények gyakorlati demonstrálására, valamint a betanított mély tanulási modellek valós idejű tesztelésére egy klinikai prototípus webalkalmazást terveztem és valósítottam meg. A szoftverfejlesztés során az elterjedt *Streamlit* nyílt forráskódú Python keretrendszert választottam, amely lehetővé tette egy magas teljesítményű, interaktív és letisztult grafikus felhasználói felület (GUI) kialakítását. A teljes projekt forráskódja és a webalkalmazás implementációja nyilvánosan elérhető a dedikált fejlesztői adattáramban [15].

5.1. Követelmény-specifikáció és tervezés

Bár a kutatómunka elsődleges fókuszát a mély tanulási modellek optimalizálása és a kísérleti fázisok képezték, a gyakorlati klinikai alkalmazhatóság demonstrálására kifejlesztett prototípus webalkalmazás megkövetelte a klasszikus szoftvermérnöki tervezési elvek alkalmazását. A fejlesztést megelőzően az alábbi specifikációkat és követelményrendszert határoztam meg.

5.1.1. Felhasználói szerepkörök

A klinikai validációs környezetben két alapvető felhasználói szerepkört különítettem el a rendszer működése és hozzáférési szintjei alapján. Ezen szerepkörök elvárásait a 5.1. táblázat foglalja össze.

5.1. táblázat. Felhasználói szerepkörök és elvárások specifikációja

Szerepkör	Leírás és elvárások a rendszerrel szemben
Klinikai szakember	Olyan végfelhasználó (orvos vagy radiológus), aki nem rendelkezik mély gépi tanulási ismeretekkel. Elsődleges igénye a gyors, intuitív és transzparens döntéstámogatás: a digitális orvosi kép feltöltése után azonnali osztályozási eredményt és vizuális magyarázatot vár el a szoftvertől.
Rendszerfejlesztő / Kutató	Technikai szerepkör, amely teljes hozzáféréssel rendelkezik a háttér-architektúrához. Feladata a betanított modellek (pl. VGG16 vagy MobileNetV2 konfigurációk) integrálása, dinamikus cseréje, valamint a futásidejű és erőforrás-kezelési paraméterek monitorozása.

5.1.2. Funkcionális és nem funkcionális követelmények

A prototípus működését, technikai korlátait és minőségi elvárásait szigorú funkcionális és nem funkcionális követelményrendszer mentén terveztem meg, amelyet a 5.2. táblázat strukturál.

5.2. táblázat. Funkcionális és nem funkcionális követelmények mátrixa


Típus	Követelmény azonosító	Leírás és technikai megvalósítás
Funkcionális	K-F-01 (Adatbefogadás)	A szoftvernek képesnek kell lennie szabványos grafikus formátumok (JPEG, PNG) fogadására a klinikai DICOM fájlok exportjából származtatva.
	K-F-02 (Modellválasztás)	Biztosítani kell egy interaktív felületet, ahol a felhasználó manuálisan kiválaszthatja, melyik kísérleti fázisból származó neurális hálót kívánja futtatni.
	K-F-03 (Inferancia és XAI)	A rendszernek végre kell hajtania a bináris osztályozást (NORMAL/PNEUMONIA), ki kell jeleznie a konfidenciaszintet, és le kell generálnia a Grad-CAM hőterképet.
Nem funkcionális	K-NF-01 (Válaszidő)	Az orvosi munkafolyamatok időkénszere miatt a kép feltöltésétől az eredmények megjelenéséig eltelt idő nem haladhatja meg a 3-5 másodpercet.
	K-NF-02 (Transzparencia)	A rendszer nem működhet „fekete dobozként”; a Grad-CAM hőterkép megjelenítése kötelező érvényű a klinikai elfogadhatóság érdekében.
	K-NF-03 (Hordozhatóság)	A Streamlit keretrendszer használatával biztosítani kell, hogy az alkalmazás platformfüggetlenül, tetszőleges webböngészőből elérhető legyen.

5.1.3. A rendszer használati esetei (Use Case)

A tipikus klinikai munkafolyamat során a szoftver működése egy lineáris használati esetet követ. A klinikai szakember bejelentkezés nélkül eléri a lokálisan vagy szerveren futó Streamlit interfészt. Feltölti a páciens tüdőrontgen-felvételét, majd a legördülő menü segítségével kiválasztja az optimális modellt (például a legmagasabb pontosságú *VGG16 Combined* vagy a peremhálózati *MobileNetV2 Combined* architektúrát).

A háttérrendszer automatikusan végrehajtja a kép előfeldolgozását (méretezés, CLAHE kontraszt-kiegyenlítés), meghívja a kiválasztott modellt, majd a felületen dinamikusan frissíti a nézetet: bal oldalon az eredeti röntgenfelvétel, jobb oldalon a Grad-CAM hő térképpel fuzionált kép jelenik meg, az oldalsávban pedig a számszerűsített diagnosztikai javaslat olvasható.

Az alkalmazás működési logikáját, a funkcionális határvonalakat és a különböző felhasználói interakciókat a 5.1. ábrán látható használati eset (use-case) diagram szemlélteti strukturált formában.




5.1. ábra. A klinikai prototípus webalkalmazás használati eset (use-case) diagramja

5.2. Főbb funkcionális modulok

Az alkalmazás architektúrája és felhasználói felülete két fő funkcionális területre különül el, amelyek lefedik mind a statisztikai kiértékelést, mind a klinikai diagnosztikai támogatást:


1. **Interaktív modellstatisztikák és összehasonlító irányítópult:** Ebben a modulban a rendszer a háttérben, .json formátumban tárolt historikus kiértékelési adatokból dinamikusan építi fel a teljesítmény-mátrixot. A *Plotly* grafikus motor segítségével interaktív oszlopdiaagramokon és radar-vizualizációkon keresztül mutatja be a modellek pontosságát, ROC-AUC értékeit, valamint osztályszintű felidézési (Recall) rátáit. Ez a felület közvetlen objektív összehasonlítást nyújt a szakemberek számára a különböző architektúrák klinikai szelektivitásáról.



5.2. ábra. A webalkalmazás interaktív statisztikai irányítópultja (Model Statistics fül)

2. **Valós idejű tüdőrontgen-analízis (Inference):** A klinikai modul lehetővé teszi, hogy a felhasználó tetszőleges digitális tüdőrontgen-felvételt (JPEG vagy PNG formátumban) töltsön fel a felületre. Egy legördülő menü segítségével kiválasztható a háttérben tárolt betanított hálózatok egyike (pl. a kombinált adathalmazon nevelt VGG16 vagy MobileNetV2). A rendszer elvégzi a dedikált előfeldolgozást, lefuttatja a predikciót, majd vizuálisan megjeleníti a diagnosztikai eredményt (*NORMAL* vagy *PNEUMONIA*) a hozzá tartozó konfidenciaszinttel együtt.


3. **Döntéstámogató Grad-CAM vizualizáció:** A mély neurális hálózatok klinikai alkalmazhatóságának legfőbb gátja a strukturális „fekete doboz” (black box) jelenség, azaz a döntési folyamatok átláthatatlansága. Ennek feloldására a predikciós motor mellé integráltam a Grad-CAM (Gradient-weighted Class Activation Mapping) algoritmust. A rendszer kinyeri az utolsó konvolúciós réteg gradienseit, és egy színes hő térképet (heatmap) vetít rá az eredeti röntgenképre, megmutatva, hogy a hálózat mely anatómiai régiók (pl. tüdőlebenyi infiltrátumok) alapján hozta meg a döntését.



5.3. ábra. A valós idejű diagnosztikai modul működés közben a Grad-CAM hő térképpel kiegészítve

5.3. Rendszerarchitektúra és adatáramlás

A klinikai prototípus belső szoftverarchitektúráját úgy terveztem meg, hogy az kövesse a modern, eseményvezérelt és reaktív mikroszolgáltatás-szerű mintákat. Amikor a felhasználó interakcióba lép a grafikus felülettel (képet tölt fel vagy modellt vált), a Streamlit egy fentről lefelé irányuló végrehajtási ciklust indít el. Az adatok áramlását és a funkcionális komponensek egymásra épülését a 5.4. ábrán látható folyamatdiagram szemlélteti.



5.4. ábra. A webalkalmazás belső adatáramlási és feldolgozási szekvenciadiagramja

Az adatáramlási lánc szigorúan determinisztikus, és négy egymásra épülő fázisból áll:

1. **Adatbefogadási fázis (Ingestion):** A felhasználó (klinikai szakember vagy kutató) feltölti a vizsgálni kívánt tüdőröntgen felvételt szabványos JPEG vagy PNG formátumban (amelyek a klinikai gyakorlatban a nyers DICOM orvosi képfájlok exportálásából származnak) [15]. A Streamlit felülete a feltöltött állományt a háttérben automatikusan egy Python-alapú PIL (Pillow) Image objektummá konvertálja a memóriában, miközben a felhasználó a legördülő menüből kiválasztja a futtatni kívánt predikciós modellt [15].
2. **Dinamikus transzformációs fázis (Preprocessing):** A rendszer a kiválasztott modell típusától függően ágaztatja el a végrehajtást. Szükség esetén meghívja a háttérben futó U-Net szegmentációs hálót, elvégzi az aszimmetrikus vágást, majd végrehajtja a LAB-színtér alapú CLAHE lokális kontraszt-kiegyenlítést. A fázis végén megtörténik a célarchitektúrára (pl. VGG16 vagy MobileNetV2) szabott ImageNet-alapú normalizáció.

3. **Következtetési fázis (Inference):** Az előkészített, immár 4D tenzor formátumú adatsomagot megkapja a memóriában gyorsítótárazott (cache-elt) Keras modell, amely elvégzi a matematikai előreecsatolást (*forward pass*), és visszaadja a tüdőgyulladás jelenlétére vonatkozó valószínűségi értéket.
4. **Diagnosztikai vizualizációs fázis (Explanability):** Amennyiben a kiválasztott hálózat konvolúciós rétegei támogatják, a predikcióval párhuzamosan lefut a Grad-CAM hőterkép-generátor. A kód kiszámítja a gradienseket, előállítja az aktivációs súlyokat, majd a kész vizuális diagnosztikai riportot (az osztályozási eredményt, a konfidenciaszintet és a magyarázó hőterképet) szinkronban kirajzolja a webes felületre.

5.4. Modellkezelés és erőforrás-optimalizálás

A webalkalmazás stabilitása és a minimális válaszidő biztosítása érdekében kritikus fontosságú volt a modellek memóriakezelésének optimalizálása. Mivel a VGG16-alapú modellek mérete és paraméterszáma jelentős, a hagyományos szoftveres betöltés minden egyes felhasználói interakció (gombnyomás, képfrissítés) során újraolvasná a fájlrendszert, ami memóriatúlcsorduláshoz és elfogadhatatlan késleltetéshez vezetne.

Ezt a problémát a Streamlit erőforrás-gyorsítótárazó (@st.cache_resource) dekorátorának alkalmazásával oldottam meg. Ez a mechanizmus garantálja, hogy az adott .keras hálózat vagy az U-Net tüdőszegmentációs modell csak az első meghíváskor töltődik be a fizikai memóriába, a későbbi elemzések során a rendszer azonnal a cache-ből éri el a modelleket.

```
@st.cache_resource
def load_keras_model(model_name):
    model_path = os.path.join("models", f"{model_name}.keras")
    if os.path.exists(model_path):
        return tf.keras.models.load_model(model_path)
    return None

@st.cache_resource
def load_unet_model():
    unet_path = os.path.join("models", "UNET_lung_seg.hdf5")
    if not os.path.exists(unet_path):
        unet_path = os.path.join("models", "UNET_model.keras")
    if os.path.exists(unet_path):
        return tf.keras.models.load_model(unet_path, compile=False)
    return None
```

5.1. Listing. A modellek hatékony betöltése és gyorsítótárazása

5.5. Intelligens, dinamikus előfeldolgozási réteg

A webalkalmazás egyik legfontosabb szoftvermérnöki komponense a dinamikus és teljesen automatizált előfeldolgozó csővezeték (*preprocessing pipeline*). Mivel a rendszernek képesnek kell lennie kiszolgálni a korábbi fejezetekben bemutatott összes kísérleti konfigurációt, a háttérkód a kiválasztott modell elnevezéséből adódó string-mintázat alapján automatikusan határozza meg a szükséges transzformációkat.

Ha a felhasználó egy *U-Net* alapú modellt választ ki, a rendszer meghívja a tüdőszegmentációs hálót, legenerálja a bináris maszkot, kontúranalízis segítségével kiszámítja a befoglaló téglalapot (*bounding box*), majd elvégzi a vágást. Ha a modell nevében szerepel a *crop* kifejezés, a kód végrehajtja a determinisztikus, fixált aszimmetrikus vágást (felülről 15%, alulról 10%, oldalakról 5% elhagyásával). Amennyiben a modell *CLAHE* konfigurációt igényel, az *OpenCV* könyvtár segítségével a kép átalakításra kerül LAB színtérbe, az L csatornán lefut a lokális kontraszt-kiegyenlítés, majd a visszaalakított RGB képen végbemegy az architektúra-specifikus (pl. VGG16 vagy MobileNetV2) normalizáció.

```
def preprocess_image(image, model_name, target_size=(224, 224), unet_model=None):
    img_array = np.array(image)
    name_lower = model_name.lower()

    # 1. U-Net alapu intelligens td-szegmentacio es vgas
    if "UNET" in name_lower and unet_model is not None:
        img_uint8 = np.clip(img_array, 0, 255).astype(np.uint8)
        unet_input_shape = unet_model.input_shape
        unet_img_size = (UNET_INPUT_SHAPE[1], UNET_INPUT_SHAPE[2])
        img_UNET = cv2.resize(img_uint8, unet_img_size) / 255.0
        if unet_input_shape[3] == 1:
            img_UNET = np.expand_dims(cv2.cvtColor((img_UNET *
255).astype(np.uint8), cv2.COLOR_RGB2GRAY) / 255.0, axis=-1)
            img_tensor = np.expand_dims(img_UNET, axis=0).astype(np.float32)
            mask = unet_model(img_tensor, training=False)[0].numpy()
            mask_resized = np.squeeze(cv2.resize(mask, (img_array.shape[1],
img_array.shape[0])))
            mask_BINARY = (mask_resized > 0.5).astype(np.uint8)
            masked_img = cv2.bitwise_and(img_uint8, img_uint8, mask=mask_BINARY)
            contours, _ = cv2.findContours(mask_BINARY, cv2.RETR_EXTERNAL,
cv2.CHAIN_APPROX_SIMPLE)
            if contours:
                x, y, w, h = cv2.boundingRect(max(contours, key=cv2.contourArea))
                pad = 10
                img_array = masked_img[max(0, y-pad):min(img_array.shape[0], y+h+pad),
max(0, x-pad):min(img_array.shape[1], x+w+pad)]
                img_array = cv2.resize(img_array, target_size)

    # 2. Determinisztikus aszimmetrikus center crop
    elif "CROP" in name_lower:
```



```

img_uint8 = np.clip(img_array, 0, 255).astype(np.uint8)
h, w = img_uint8.shape[:2]
img_array = cv2.resize(img_uint8[int(h*0.15):int(h*0.90),
int(w*0.05):int(w*0.95)], target_size)
else:
    img_array = np.array(image.resize(target_size))

# 3. Kontraszt-javítás LAB színtér CLAHE eljárással
if "clahe" in name_lower:
    img_uint8 = np.clip(img_array, 0, 255).astype(np.uint8)
    lab = cv2.cvtColor(img_uint8, cv2.COLOR_RGB2LAB)
    l, a, b = cv2.split(lab)
    cl = cv2.createCLAHE(clipLimit=2.0, tileGridSize=(8, 8)).apply(l)
    img_array = cv2.cvtColor(cv2.merge((cl, a, b)), cv2.COLOR_LAB2RGB)

display_image = Image.fromarray(np.uint8(img_array))
img_array = np.expand_dims(img_array.astype(np.float32), axis=0)

# 4. Modell-specifikus normalizáció meghívása
if "resnet" in name_lower or "densenet" in name_lower:
    img_array = img_array / 255.0
elif "efficientnet" in name_lower:
    img_array = tf.keras.applications.efficientnet.preprocess_input(img_array)
elif "mobilenet" in name_lower:
    img_array = tf.keras.applications.mobilenet_v2.preprocess_input(img_array)
elif "vgg" in name_lower:
    img_array = tf.keras.applications.vgg16.preprocess_input(img_array)

return img_array, display_image

```

5.2. Listing. A dinamikus és automatizált előfeldolgozási logika

5.6. A Grad-CAM hőkép szoftveres generálása

A vizuális magyarázhatóságért felelős Grad-CAM motor egy egyedi funkcionális rétegen keresztül valósul meg. Az eljárás első lépéseként a kód lekérdezi az adott hálózat utolsó konvolúciós rétegének pontos nevét (pl. VGG16 esetén "block5_conv3", MobileNetV2 esetén "out_relu"). Ezt követően felépít egy többszörös kimenetű Keras részmodellt, amely egyszerre adja vissza a cél-konvolúciós réteg aktivációs térképét és a hálózat végleges predikcióját.

Egy automatikus gradienstranszformációs szalag (`tf.GradientTape`) segítségével kiszámítja a predikált osztály pontszámának konvolúciós jellemzőterképek szerinti gradienseit, majd a csatornánkénti átlagolás után végrehajtja az aktivációs térképek súlyozott összegzését. Az így kapott mátrixot a negatív hatások kiszűrése érdekében egy ReLU operátornak veti alá, normalizálja, végül a `matplotlib` Jet színpalettájával

mintázva 40%-os áttetszőség mellett rávetíti az előfeldolgozott röntgenképre.

```
def make_gradcam_heatmap(img_array, model, last_conv_layer_name):
    grad_model = tf.keras.models.Model(
        model.inputs, [model.get_layer(last_conv_layer_name).output, model.output]
    )
    with tf.GradientTape() as tape:
        inputs = tf.cast(img_array, tf.float32)
        last_conv_layer_output, preds = grad_model(inputs)
        if isinstance(preds, list):
            preds = preds[0]
        class_channel = preds[0][0] if preds.shape[-1] == 1 else preds[:,
tf.argmax(preds[0])]

    grads = tape.gradient(class_channel, last_conv_layer_output)
    pooled_grads = tf.reduce_mean(grads, axis=(0, 1, 2))
    heatmap = last_conv_layer_output[0] @ pooled_grads[..., tf.newaxis]
    heatmap = tf.squeeze(heatmap)
    heatmap = tf.maximum(heatmap, 0) / tf.math.reduce_max(heatmap)
    return heatmap.numpy()
```

5.3. Listing. A Grad-CAM hőterkép matematikai levezetése és implementációja

5.7. A rendszer mappaszerkezete és komponensei

A tiszta szoftverfejlesztési elveknek és a modularitás követelményeinek megfelelően a prototípus webalkalmazás projektstruktúráját az alábbi átlátható struktúra szerint alakítottam ki:

```
webapp/
  app.py           # A Streamlit alkalmazás fokodja es a GUI
  definicioja
  metrics/         # A halozatok kiertekelesi eredmenyei (.json fajlok)
  models/          # A betanított súlyok es szegmentációs halok
  (.keras / .hdf5)
```

A nagyméretű, betanított modellsúlyok elérése (.keras fájlok) lokálisan biztosított a Streamlit futtatókörnyezet számára, így garantálva a minimális válaszidőt és a hálózati késleltetéstől mentes működést az orvosi képek elemzése során. A moduláris felépítésnek köszönhetően a rendszer rendkívül könnyen skálázható: újabb modellek integrálásához elegendő a súlyfájlt a *models/*, míg a hozzá tartozó osztályozási reportot a *metrics/* mappába helyezni, amit az alkalmazás a következő indításkor automatikusan felismer és beépít a felületre.

5.8. A rendszer online elérhetősége

A kifejlesztett klinikai prototípus webalkalmazás a gyakorlatban is tesztelhető és publikusan elérhető. A könnyebb hozzáférhetőség és a közvetlen kipróbálhatóság érdekében a Streamlit alkalmazást a Hugging Face Spaces felhőalapú platformján helyeztem üzembe.

A működő prototípus az alábbi hivatkozásra kattintva érhető el:

<https://balazsakos03-chestxray-streamlit-app.hf.space/>

Az online környezet tartalmazza a betanított és optimalizált modelleket, így a felhasználói felületen keresztül azonnal elvégezhető a feltöltött tüdőrontgen-felvételek osztályozása, valamint a Grad-CAM alapú vizuális magyarázatok generálása.

6. fejezet

Összegzés és jövőbeli irányok

A diplomamunka keretében végzett kutató- és fejlesztőmunka során szisztematikusan feltérképeztem és transzformáltam a mély tanulású konvolúciós neurális hálózatok (CNN) alkalmazhatósági határait a digitális tüdőröntgen-felvételt alkalmazó automatizált diagnosztikában. Az iteratív módon felépített, tizennégy kísérleti fázisból álló kutatási folyamat egyértelműen igazolta, hogy a transzfer tanulás módszertana, valamint a korszerű, előtanított mély architektúrák (*VGG16*, *DenseNet121*, *MobileNetV2*) alapvető és nélkülözhetetlen pillérei az orvosi képfeldolgozásnak, ahol a korlátozott mintaszám miatt a nulláról történő hálózatépítés nem nyújt klinikailag elfogadható hatékonyságot.

A kutatási projekt egyik legfontosabb eredménye a **preprocessing és az adathalmaz-fúzió szinergiája**. Bebizonyosodott, hogy a determinisztikus aszimmetrikus center crop és a LAB-szintéren végrehajtott CLAHE kontraszt-kiegyenlítés szignifikánsan javítja a modellek belső szelektivitását. A projekt abszolút csúcsteljesítményét nyújtó VGG16 Combined konfiguráció 99,11%-os globális pontossága és 0,9984-es ROC-AUC értéke egyértelműen igazolja a választott módszertan kiválóságát.

Kiemelendő emellett a **Domain Shift jelenség számszerűsítése**. A kereszt-adatkészletes (*cross-dataset*) validációk során empirikus bizonyítékot szolgáltattam a domain shift teljesítményromboló hatására. Kulcsfontosságú módszertani konklúzió, hogy a bonyolult, szintén domain-érzékeny szegmentációs eljárások helyett a tanító-adatok demográfiai és technikai diverzifikálása (azaz az adatkészlet-fúzió) jelenti a leginkább robusztus és stabil megoldást a gyakorlatban.

A szoftverfejlesztési fázis hozzájárult a **klinikai transzparencia (XAI)** növeléséhez is. A kifejlesztett Streamlit webalkalmazás és a Grad-CAM algoritmus sikeresen hidalja át a mélytanulás strukturális „fekete doboz” problémáját. A vizuális hőtérképes magyarázhatóság közelebb hozza a rendszert a magyarázható mesterséges intelligencia klinikai integrációjához, ami közvetlenül növelheti az orvosszakmai bizalmat.

Végezetül igazolást nyert a **peremhálózati megvalósíthatóság** lehetősége is. A MobileNetV2 Combined modellel bizonyítottam, hogy a mélységében szétválasztható konvolúciók alkalmazásával a paraméterszám drasztikus csökkentése mellett is elérhető

klinikailag releváns, 97,33%-os pontosság, ami megnyitja az utat az alacsony számítási kapacitású, hordozható orvosi eszközökre történő integráció előtt.

6.1. Jövőbeli fejlesztési irányok

A megvalósított diagnosztikai platform stabil mérnöki alapokat biztosít, amely a jövőben több kritikus irányban fejleszthető tovább. Első lépésként kiemelten fontos a **többosztályos (Multiclass) osztályozás bevezetése**. A jelenlegi bináris felosztás kiterjesztése orvosilag rendkívül indokolt, így a jövőbeli kutatások elsődleges célja a tüdőgyulladásos belüli etiológiák (bakteriális vs. vírusos, különös tekintettel a COVID-19-re), valamint egyéb tüdőpatológiák, mint a tuberkulózis vagy a légmell differenciál-diagnosztikai szeparációja.

További komoly előrelépést jelenthet az **U-Net alapú finomhangolás saját adatain**. Bár az U-Net alapú szegmentáció a domain shift miatt jelenleg korlátozottabb robusztusságot mutatott, a modell saját, diverzifikált tudómaszk-adatbázison történő finomhangolásával (*fine-tuning*) egy olyan stabil szegmentációs előszűrő hozható létre, amely hatékonyan kiküszöböli a nem-anatómiai háttérzajokat anélkül, hogy torzítná a pediátriai mintákat.

Végezetül távlati célként a **multimodális adatfúzió** megvalósítása javasolt. A diagnosztikai biztonság jelentősen növelhető a képi információk és a strukturált klinikai metaadatok – mint például a páciens életkora, laboratóriumi gyulladásos markerei és klinikai tünetei – együttes, multimodális hálózatba történő csatornázásával, ami még közelebb emeli a rendszert a valódi kórházi munkafolyamatokhoz.

Összességében a diplomamunka során kifejlesztett architektúra-együttes és a prototípus szoftver sikeresen bizonyította, hogy a tudatosan tervezett adat-előkészítési csővezeték alkalmazó mély tanulási modellek megbízható, gyors és transzparens objektív döntéstámogató eszközként képesek szolgálni a radiológiai diagnosztikában.

Irodalomjegyzék

- [1] Krizhevsky, A., Sutskever, I., Hinton, G. E.: *ImageNet Classification with Deep Convolutional Neural Networks*. In: Advances in Neural Information Processing Systems (NeurIPS), vol. 25, 2012, pp. 1097–1105. DOI: <https://doi.org/10.1145/3065386>
- [2] He, K., Zhang, X., Ren, S., Sun, J.: *Deep Residual Learning for Image Recognition*. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2016, pp. 770–778. DOI: <https://doi.org/10.1109/CVPR.2016.90>
- [3] Huang, G., Liu, Z., Van Der Maaten, L., Weinberger, K. Q.: *Densely Connected Convolutional Networks*. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2017, pp. 4700–4708. DOI: <https://doi.org/10.1109/CVPR.2017.243>
- [4] Tan, M., Le, Q.: *EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks*. In: International Conference on Machine Learning (ICML), PMLR vol. 97, 2019, pp. 6105–6114. Hivatalos forrás: <https://proceedings.mlr.press/v97/tan19a.html>
- [5] Sandler, M., Howard, A., Zhu, M., Zhmoginov, A., Chen, L. C.: *MobileNetV2: Inverted Residuals and Linear Bottlenecks*. In: Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), 2018, pp. 4510–4520. DOI: <https://doi.org/10.1109/CVPR.2018.00474>
- [6] Simonyan, K., Zisserman, A.: *Very Deep Convolutional Networks for Large-Scale Image Recognition*. In: International Conference on Learning Representations (ICLR), 2015. DOI: <https://doi.org/10.48550/arXiv.1409.1556>
- [7] Nair, V., Hinton, G. E.: *Rectified Linear Units Improve Restricted Boltzmann Machines*. In: International Conference on Machine Learning (ICML), 2010, pp. 807–814. Hivatalos egyetemi forrás: <https://www.icml.cc/2010/papers/432.pdf>
- [8] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., Salakhutdinov, R.: *Dropout: A Simple Way to Prevent Neural Networks from Overfitting*. In: Journal of

Machine Learning Research (JMLR), vol. 15, no. 1, 2014, pp. 1929–1958. Hivatalos forrás: <https://jmlr.org/papers/v15/srivastava14a.html>

- [9] Ioffe, S., Szegedy, C.: *Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift*. In: International Conference on Machine Learning (ICML), PMLR vol. 37, 2015, pp. 448–456. Hivatalos forrás: <https://proceedings.mlr.press/v37/ioffe15.html>
- [10] Zuiderveld, K.: *Contrast Limited Adaptive Histogram Equalization*. In: Graphics Gems IV, Academic Press Professional, Elsevier, 1994, pp. 474–485. DOI: <https://doi.org/10.1016/B978-0-12-336156-1.50061-6>
- [11] Selvaraju, R. R., Cogswell, M., Das, A., Vedantam, R., Parikh, D., Batra, D.: *Grad-CAM: Visual Explanations from Deep Networks via Gradient-based Localization*. In: Proceedings of the IEEE International Conference on Computer Vision (ICCV), 2017, pp. 618–626. DOI: <https://doi.org/10.1109/ICCV.2017.74>
- [12] Kermany, D. S., Goldbaum, M., Wen, W. et al.: *Identifying Medical Diagnoses and Processes in Image-Based Datasets*. In: Cell, vol. 172, no. 5, Elsevier, 2018, pp. 1122–1131. DOI: <https://doi.org/10.1016/j.cell.2018.02.010>
- [13] Rahman, T., Khandakar, A., Qiblawey, Y. et al.: *Exploring the Effect of Image Enhancement Techniques on COVID-19 Detection Using Chest X-Rays*. In: Computers in Biology and Medicine, vol. 132, Elsevier, 2021, p. 104319. DOI: <https://doi.org/10.1016/j.compbiomed.2021.104319>
- [14] U-Net Lung Segmentation GitHub Repository. Elérhető: <https://github.com/harsha-20/Medical-Image-Segmentation>
- [15] Tüdőröntgen felvételek osztályozása mély tanulású neurális hálózatokkal. Saját GitHub Repository. Elérhető: https://github.com/balazsakos03/allamvizsga_tudorontgen_BalazsAkos